

深度学习与大语言模型

前沿技术全景报告

版本：2026 年 9 月

定位：系统性技术参考

覆盖：从基础数学到 2026 年前沿架构

本报告的章节结构：12 个主章节 + 术语附录，涵盖深度学习数学基础、Transformer 架构、LLM 训练流水线、MoE/GQA/MLA 前沿架构、推理优化、推理模型、多模态、安全对齐、可扩展性定律及 2025-2026 行业动态。

目录

1 深度学习基础：从神经元到反向传播	5
1.1 神经元与计算图	5
1.2 激活函数	6
1.3 反向传播与优化器	7
1.4 正则化与训练稳定性	8
1.5 损失函数	9
2 经典架构演进：CNN → RNN → Transformer	9
2.1 CNN：局部特征提取	9
2.2 RNN / LSTM / GRU：序列建模	10
2.3 Transformer：范式革命	11
3 Transformer 深度剖析：注意力机制的数学本质	12
3.1 标准 Transformer 架构	12
3.2 自注意力机制：数学细节	13
3.2.1 单头注意力	13
3.2.2 多头注意力	14
3.3 位置编码	14
3.4 解码器 vs 编码器	15
4 大语言模型 (LLM) 训练流水线	16
4.1 阶段一：预训练 (Pre-training)	17
4.1.1 分布式训练策略	17
4.1.2 典型超参数	18
4.1.3 容错与检查点	19
4.2 阶段二：监督微调 (SFT)	19
4.3 阶段三：人类对齐 (Alignment)	20
4.3.1 RLHF：基于人类反馈的强化学习	20
4.3.2 DPO：直接偏好优化	21
4.3.3 Constitutional AI (Anthropic)	21
4.4 持续学习与更新	22
5 前沿架构创新	22
5.1 混合专家 (Mixture of Experts, MoE)	22
5.2 注意力机制变体	24
5.2.1 GQA (Grouped Query Attention)	24
5.2.2 MLA (Multi-head Latent Attention)	25

5.2.3	滑动窗口注意力	25
5.2.4	线性注意力与状态空间模型	25
5.3	代表性架构创新	26
6	推理优化	26
6.1	推理瓶颈分析	26
6.2	KV Cache 优化	27
6.3	量化技术	28
6.4	推测解码 (Speculative Decoding)	28
6.5	推理引擎与系统优化	29
7	推理模型 (Reasoning Models)	30
7.1	从 CoT 到 System 2	30
7.2	代表性推理模型	30
7.2.1	DeepSeek-R1 的核心创新	31
7.3	过程奖励模型 (PRM)	33
7.4	推理训练技术栈	34
7.5	推理的边界与局限	34
8	多模态大模型	34
8.1	架构范式	34
8.2	视觉语言模型 (VLM)	35
8.3	音频/语音	36
8.4	视频理解与生成	36
8.5	多模态训练与推理	37
9	安全、对齐与治理	38
9.1	对齐技术栈	38
9.2	关键安全挑战	39
9.3	治理与监管	39
10	可扩展性定律与未来方向	40
10.1	Scaling Laws 演进	40
10.1.1	Kaplan Scaling Laws (2020)	40
10.1.2	Chinchilla Scaling Laws (2022)	40
10.1.3	超越 Chinchilla	41
10.2	数据墙与计算墙	42
10.3	能力收敛假说 (CCH): 能力由访问结构定价	42
10.3.1	能力的操作化定义: 历史-查询通道	43

10.3.2 访问结构：双通道完备类	43
10.3.3 见证任务与三堵墙	44
10.3.4 用 CCH 回照本报告：访问结构的工程版图	44
10.4 未来方向（2025-2030）	45
11 2025-2026 行业前沿动态	46
11.1 2025 年时间线：从 DeepSeek 冲击波到多极格局	47
11.2 中国力量：从追赶到并跑	48
11.3 算力、资本与开源生态	49
12 总结与展望	49
12.1 技术栈全景	49
12.2 核心趋势	50
12.3 给学习者的建议	51
A 关键术语速查表	52
B 关键论文与延伸阅读	55

摘要与导读

本报告系统梳理了从深度学习数学基础到大语言模型（LLM）前沿技术的完整技术栈，回答三个核心问题：**大模型如何被构建、如何被训练、如何被对齐与治理**。全文按“基础原理 → 架构演进 → 训练系统 → 推理系统 → 能力扩展 → 安全治理 → 产业动态”的逻辑链条组织：第 1–2 章奠定数学基础并回顾架构演进史；第 3–4 章深入剖析 Transformer 机制与 LLM 训练流水线；第 5–6 章覆盖 MoE、GQA/MLA 等前沿架构与推理优化体系；第 7–8 章讨论推理模型（Reasoning Models）与多模态大模型；第 9–10 章面向安全对齐、可扩展性定律与长期趋势，其中 10.3 节引入**能力收敛假说**（CCH）——“表征收敛由规模免费赠予，能力收敛必须由访问结构购买”——作为贯通架构（第 5 章）、推理系统（第 6–7 章）与趋势判断（第 10、12 章）的理论主线；第 11–12 章汇总 2025–2026 年行业动态并给出总结与展望。

阅读建议（按读者画像）：

- **初次接触者**：按顺序通读第 1→3 章建立直觉，再按兴趣深入后续章节；
- **训练/推理工程师**：重点阅读第 4、6 章的分布式系统与推理优化细节；
- **算法研究者**：重点关注第 5、7、10 章的前沿架构、推理训练与 Scaling Law 分析；
- **技术与产品决策者**：重点阅读本摘要、第 10–11 章趋势判断与第 12 章展望。

方法与数据来源说明

本报告以公开论文、技术报告与官方文档为主要信息源。关键定量结论（如 DeepSeek-V3 的 671B 总参数 / 37B 激活参数 / 2.79M H800 GPU·hours 训练成本、Qwen3-235B-A22B 的 128 专家 / 激活 8、LLaMA-2 70B 的 GQA 实验等）均引用自原始技术报告或论文。行业动态截至 2026 年 9 月：2025 年的主要事件（GPT-5、Gemini 3、Claude Opus 4.5、Qwen3、Kimi K2、Sora 2 等）与 NVIDIA 收购 Hugging Face（约 129 亿美元，2026 年 8 月官宣）均经多个公开报道交叉核实；2026 年上半年个别事件（如 Gemini 3.7 等）的量化细节以最终官方披露为准，读者引用时建议回溯原始来源核实。

图 1 给出全文的宏观结构：**基础层**回答“深度学习为什么可行”，**模型与系统层**回答“大模型如何被构建、训练与高效部署”，**能力层**回答“如何让它更会推理、看见世界”，**规律与治理层**回答“边界在哪里、如何被约束”，**生态层**回答“谁在做什么、往哪里去”。各章末尾的小结框（infobox/keybox）均可独立阅读，作为该章的“电梯演讲”版本。



图 1: 报告宏观架构：五个层次自底向上堆叠，每层依赖下一层；括号内为对应章节。

1 深度学习基础：从神经元到反向传播

1.1 神经元与计算图

深度学习的原子单元是**人工神经元**。一个神经元接收输入向量 $\mathbf{x} \in \mathbb{R}^n$ ，计算加权和 $z = \mathbf{W} \cdot \mathbf{x} + b$ ，再通过**激活函数** σ 得到输出 $a = \sigma(z)$ 。整个网络就是成千上万个这样的单元按特定拓扑连接而成的**计算图** (Computation Graph)。

现代 LLM 中，单个“神经元”的概念已弱化，取而代之的是矩阵运算和块状结构 (block)，但底层数学不变：

$$\text{output} = \sigma \left(\sum_i W_i x_i + b \right)$$

在 GPU 上，一次前向传播本质上是若干**大矩阵乘法** (GEMM) 与逐元素激活的组合。这也是深度学习天然适合并行硬件的原因。

从神经元到矩阵：现代 LLM 的视角

$$\text{单个神经元: } a = \sigma(\mathbf{w}^\top \mathbf{x} + b)$$

$$\text{一层线性变换 (n 个神经元): } \mathbf{z} = \mathbf{W}\mathbf{x} + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{n \times d}$$

$$\text{一个 LLM Block: } \mathbf{h} = \mathbf{x} + \text{Attn}(\text{RMSNorm}(\mathbf{x})) \rightarrow \mathbf{h} + \text{FFN}(\text{RMSNorm}(\mathbf{h}))$$

换言之，现代大语言模型中的“线性层”就是这样一个“神经元阵列”：以 LLaMA-2 7B 为例，每个注意力 QKV 投影矩阵约 4096×4096 ，一个前馈 SwiGLU 层约有 3 个 4096×11008 的大矩阵——模型的“智能”正是分布在这数百个巨型矩阵的数值之中。

把视角再抬高一层的直观理解是：**学习就是在一个巨大的计算图上搜索“最优的旋钮组合”**。以 7B 模型为例，约 70 亿个参数就是 70 亿个旋钮；训练的过程，是让数万亿 token 依次流过计算图，用每次预测的误差（梯度）反向微调所有旋钮，直到整个网络对“下一个 token”的猜测足够准。这句话里藏着深度学习的三个支点：可微（损失对参数处处可导，梯度存在）、可反向传播（链式法则把误差按贡献归因到每个参数）、可并行（大矩阵乘法主导，天然适配 GPU）。第 4-6 章的所有工程奇迹，本质上都是在放大这三个支点。图 2 给出了这一全景。




图 2: 深度学习的三个基本视图：(a) 人工神经元；(b) 计算图上的前向传播与反向传播；(c) 多层感知机——现代 LLM 就是把 (c) 的宽度与深度放大七个数量级、再把隐藏层换成注意力与 SwiGLU 的产物。

核心洞察：深度学习的计算本质

深度学习的所有操作——卷积、注意力、前馈——在底层都可以归结为**矩阵乘法**和**逐元素变换**。GPU 的 Tensor Core 专为大矩阵乘法优化，这使得深度学习训练/推理能在数百到数千张 GPU 上并行执行，吞吐量达数十 PFLOPS。

1.2 激活函数

激活函数引入**非线性**，使网络能拟合任意复杂函数。非线性之所以不可或缺，是因为线性变换的复合仍是线性变换——若没有激活函数，再深的网络也只是单个线性映射 $y = (W_L \cdots W_1)x + \mathbf{b}$ ，表达能力与单层无异。因此激活函数是“深度”产生意义的根本

前提。

工程上，激活函数的选择需权衡三点：**计算代价**（tanh 类需要指数运算，ReLU/GELU 近似更廉价）、**梯度特性**（负区间梯度是否消失）、**平滑性**（ReLU 在 0 点不可导，训练大模型时 GELU/SiLU 的平滑性更友好）。下表汇总了主流激活函数：

函数	公式	特点
Sigmoid	$1/(1 + e^{-x})$	输出 (0, 1)，梯度消失严重
Tanh	$(e^x - e^{-x})/(e^x + e^{-x})$	输出 (-1, 1)，零中心
ReLU	$\max(0, x)$	计算快，但存在“死亡神经元”
GELU	$x \cdot \Phi(x)$	LLaMA、GPT 系列主流，平滑
SwiGLU	$\text{Swish}(xW_1) \odot (xW_2)$	LLaMA/LLM 前馈层首选
SiLU / Swish	$x \cdot \sigma(x)$	门控激活
GEGLU	$\text{GeLU}(xW_1) \odot (xW_2)$	GLM、Falcon 使用

表 1: 主流激活函数对比

趋势：门控激活成为 LLM 标配

现代 LLM 普遍采用 **SwiGLU** 或 **GEGLU** 作为 FFN 激活。相比 ReLU 有 1-3% 的困惑度 (perplexity) 优势，代价是参数量增加 50% (FFN 中有两个门控矩阵 W_1 和 W_2)。这一“用参数换精度”的权衡在大规模训练中非常划算。

1.3 反向传播与优化器

反向传播 (Backpropagation) 利用链式法则, 从损失函数出发逐层计算梯度 $\partial L/\partial W$:

$$L = \mathcal{L}(\hat{y}, y), \quad \frac{\partial L}{\partial W_k} = \frac{\partial L}{\partial \mathbf{a}_{k+1}} \cdot \frac{\partial \mathbf{a}_{k+1}}{\partial \mathbf{z}_{k+1}} \cdot \frac{\partial \mathbf{z}_{k+1}}{\partial W_k}$$

核心优化器对比：

优化器	核心思想	使用场景
SGD + Momentum	经典梯度 + 惯性	计算机视觉
Adam / AdamW	自适应学习率 + 权重解耦	LLM 主流
Lion	仅用符号更新，省显存	研究前沿
Sophia	二阶近似，收敛更快	研究前沿
Muon	2025 新兴，Transformer 表现优异	前沿探索

表 2: 主流优化器对比

反向传播的直觉可以概括为“误差的归因过程”：前向传播把输入层层加工成预测；反向传播则追问“这次预测错了，每个参数该负多少责任”——沿计算图逆行，用链式

法则把责任（梯度）按贡献比例分摊到每个参数。现代框架（PyTorch autograd）已把这一过程完全自动化，工程师只需定义前向计算；但理解它依然必要——第 4 章的激活检查点（以重算换显存）、1.4 节的梯度裁剪，以及“深层网络为何需要残差连接”（第 2 章），全部建立在这张计算图的拓扑之上。

LLM 预训练的典型 AdamW 配置： $\beta_1 = 0.9$, $\beta_2 = 0.95$, $\varepsilon = 10^{-8}$ ，学习率余弦衰减，warmup 2000–10000 步。

为什么是 AdamW 而不是 Adam：Adam 将权重衰减正则化混入自适应学习率中， λ 会被二阶矩估计 v_t 除小，导致对大梯度参数正则化不足。AdamW (Loshchilov & Hutter, 2019) 将权重衰减解耦为独立项 $w \leftarrow w - \eta(\text{Adam 更新} + \lambda w)$ ，恢复了 L2 正则的数学语义。这一细节对 Transformer 的泛化与训练稳定性有可测量的影响，因此成为 LLM 预训练的默认选择。

学习率调度同样关键：warmup 阶段让 Adam 的二阶矩估计先“热身”，避免初始步长过大导致 loss spike；其后采用余弦衰减至 10% 左右，在后期保持精细收敛。经验上，warmup 比例、峰值学习率与 batch size 三者强耦合——batch 每翻一倍，峰值学习率约可随之翻倍（线性缩放法则），这也是大规模训练调参的第一杠杆。

1.4 正则化与训练稳定性

深度学习训练是“高维非凸优化 + 有限精度 + 大规模并行”的叠加问题，稳定性工程往往与算法本身同等重要。以下逐项说明各技术在 LLM 训练中的角色：

- **Dropout：**随机丢弃神经元，防过拟合（LLM 中通常 rate = 0.1）
- **Weight Decay：** L_2 正则化（AdamW 中解耦实现）
- **归一化：**
 - **RMSNorm** 已成为 LLM 标配（比 LayerNorm 少一次均值计算，数值更稳定）
 - 原始 Transformer 使用 Post-Norm（先子层后归一化），梯度需穿过归一化层才能回传，深层易不稳；现代 LLM 几乎全部改用 Pre-Norm（先归一化再进子层）
- **Gradient Clipping：**裁剪梯度范数（ $\|\mathbf{g}\| \leq 1.0$ ），防止梯度爆炸
- **Mixed Precision：**BF16 前向/反向 + FP32 主权重，2× 加速且显存减半；2024 年底 DeepSeek-V3 进一步把 FP8 混合精度训练推向 671B 规模（对嵌入、归一化等敏感模块保留高精度），标志低精度训练进入千亿级主流
- **Gradient Accumulation：**小 batch 累积梯度模拟大 batch

工程要点：loss spike 是大规模训练的头号敌人

数百张 GPU 上训练千亿参数模型时，偶发的 **loss spike**（损失突然飙升）是最高频事故，常见诱因包括：学习率过高、数据中的异常批次、数值溢出（FP16 下更易发生，BF16 范围更大故更稳）、通信竞争条件。工业界的标准防御是： $\|g\| \leq 1.0$ 梯度裁剪 + 损失异常检测（spike 检测即回滚 checkpoint）+ 保守 warmup。这解释了为什么 LLM 训练栈看起来“保守”——能稳定跑完比单点性能更重要。

1.5 损失函数

LLM 预训练的核心损失是**交叉熵**（Cross-Entropy），等价于**负对数似然**（NLL）：

$$\mathcal{L} = - \sum_{t=1}^T \log P(x_t | x_{<t}, \theta)$$

训练目标：在给定前文条件下，**最大化下一个 token 的预测概率**。

整个预训练过程可以抽象为：

数据 → 前向传播 → 计算损失 → 反向传播 → 更新参数 → 循环

与交叉熵直接关联的评估指标是**困惑度**（Perplexity, PPL）：

$$\text{PPL} = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log P(x_t | x_{<t}) \right)$$

直观含义是“模型在每个 token 上平均在多少个候选词之间犹豫”。PPL=100 意味着平均不确定性相当于在 100 个等概率选项中选一个。训练监控中，训练损失与验证损失同时下降是健康的信号；验证损失先降后升则提示过拟合或数据配比失衡——这是判断“数据墙”逼近的最朴素手段。

最后补充一个容易被忽视的前置环节——**分词**（Tokenization）：现代 LLM 普遍使用 BPE（Byte Pair Encoding）类算法把词表压缩到 32K–150K 规模。词表大小直接决定嵌入层与输出投影的参数规模，也决定了中文等多字节语言每字占用的 token 数（token 越省，同样的上下文预算可容纳的中文内容越多）。这解释了为何各家模型在词表设计上差异显著：GPT-4 系列约 100K、LLaMA-2 约 32K、Qwen 系列约 150K。

2 经典架构演进：CNN → RNN → Transformer

2.1 CNN：局部特征提取

卷积神经网络（Convolutional Neural Network）的核心思想是**局部感受野** + **权值共享** + **平移不变性**。

关键组件：卷积层 → 归一化 → 激活 → 池化。卷积操作可以看作一组滑动窗口滤波器：

$$\text{out}[\mathbf{i}] = \sum_{\mathbf{j}} \text{in}[\mathbf{i} + \mathbf{j}] \cdot \text{kernel}[\mathbf{j}] + b$$

里程碑：LeNet (1998) → AlexNet (2012) → VGG (2014) → **ResNet** (2015) → EfficientNet (2019)。

其中 **ResNet 的残差连接** $y = F(\mathbf{x}) + \mathbf{x}$ 解决了深层网络退化问题，这一思想后来被 Transformer 直接继承（每个 block 都有 skip connection，这也是 LLM 能稳定堆叠 80–100 层的关键）。

需要澄清的是：CNN 并未退出舞台，而是转换了角色——它仍是计算机视觉、语音识别、推荐系统的主力架构，并且作为视觉编码器（ViT/ConvNeXt 谱系）成为 2025–2026 年多模态大模型（LLaVA、Qwen-VL、InternVL）的第一级组件，详见第 8 章。在纯文本 LLM 领域，CNN 确实让位于注意力架构。

CNN 留给 LLM 时代的两份遗产值得一提。其一是归纳偏置（inductive bias）的设计哲学：局部感受野、权值共享、平移不变性，本质上是在架构里“预先写入”关于数据的先验知识——数据越少，先验越值钱。ViT (2020) 证明在超大规模数据下纯注意力可以抛弃这些先验，但在端侧小数据、实时性要求高的场景（手机拍照、语音前端），CNN 的先验依然划算。其二是层级化特征的思想（LeNet → AlexNet → ResNet 一路验证的“边缘 → 纹理 → 部件 → 物体”逐级抽象），Swin Transformer 等层级化 ViT 正是把这一思想移植回注意力架构——多模态模型的视觉塔至今仍在“纯 ViT”与“层级化/卷积混合”两条路线间权衡。

2.2 RNN / LSTM / GRU：序列建模

核心思想：循环连接，隐状态 h_t 携带历史信息：

$$h_t = \tanh(W_{xh} x_t + W_{hh} h_{t-1} + b)$$

LSTM 引入三个门控机制（遗忘门 f_t 、输入门 i_t 、输出门 o_t ），用细胞状态 C_t 实现“选择性记忆”：

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f), \quad C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

GRU 简化 LSTM，用更新门 z_t 和重置门 r_t 替代：

$$z_t = \sigma(W_z[h_{t-1}, x_t]), \quad h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

RNN 的三大致命缺陷

1. **串行计算：** h_t 依赖 h_{t-1} ，无法并行，长序列极慢
2. **梯度消失/爆炸：**BPTT 链式传递中梯度指数衰减或增长

3. 长距离依赖衰减：信息经过 100+ 步后几乎完全丢失

这三个缺陷使得 RNN 无法支撑百亿参数级的大规模训练，最终被 Transformer 取代。

梯度消失的数学根源：BPTT 中， h_t 对 k 步之前隐状态的梯度形如

$$\frac{\partial h_t}{\partial h_{t-k}} = \prod_{i=0}^{k-1} \frac{\partial h_{t-i}}{\partial h_{t-i-1}}$$

即 k 个 Jacobian 矩阵的连乘。当矩阵谱半径 < 1 时该乘积按 ρ^k 指数衰减， > 1 时指数爆炸。LSTM 的门控（尤其是遗忘门对细胞状态的乘法直通）本质上是给这条梯度链装上“阀门”，缓解了但不根除该问题。Transformer 的注意力让信息以 $O(1)$ 跳数直接传递，从机制上绕开了这条指数衰减链——这是架构层面的根治。

RNN 的遗产与回潮同样值得关注。一方面，RNN 的“常数状态、线性成本”在流式与端侧场景仍有生命力：语音识别的前端、IoT 设备上的唤醒词模型至今大量使用 GRU/LSTM。另一方面，2023 年以来 RWKV、Mamba 等线性 RNN/SSM 以“训练可并行 + 推理 $O(1)$ 递推”的姿态卷土重来，证明循环思想并未过时——它们与注意力的融合（混合架构）是第 5 章的重要议题。可以说，RNN 与注意力之争不是“谁消灭谁”，而是“精确检索 vs 压缩记忆”这一对矛盾在不同成本约束下的再平衡。

2.3 Transformer：范式革命

注意力的思想并非一夜出现：2014 年 Bahdanau 等人在机器翻译中引入注意力以缓解 RNN 的信息瓶颈（Luong et al., 2015 简化为其点积形式），2017 年 Google 论文“**Attention is All You Need**”（Vaswani et al.）将注意力推广为全部序列交互机制，彻底改变了深度学习格局：

维度	RNN/LSTM	Transformer
并行度	串行 $O(T)$	全并行 $O(1)$
长距离依赖	指数衰减	$O(1)$ 跳数
可扩展性	受限于梯度	自然扩展
推理效率	无状态	需 KV Cache
硬件利用	GPU 利用率低	高（矩阵乘为主）

表 3: RNN 与 Transformer 架构对比

关键洞察

注意力机制让任意两个位置之间的信息传递只需 **1 步**，而 RNN 需要 $O(T)$ 步。这使得并行训练成为可能，是深度学习进入“规模时代”的根本原因。没有 Transformer 的并行性，就没有 GPT、LLaMA 等百亿/千亿参数模型。




图 3: 深度学习架构演进时间线 (1998–2026)：2017 年 Transformer 之前是“为特定任务设计归纳偏置”的时代，之后进入“通用架构 + 规模扩展”的时代；2024 年起竞争焦点转向推理能力与效率。

图 3 汇总了这一演进脉络。值得注意的还有“**架构冻结**”现象：2017 年至今，“注意力 + 残差 + 前馈”这一骨架几乎未变，创新集中在四个“插槽”上——位置编码（绝对 $\rightarrow$ RoPE）、注意力变体（MHA $\rightarrow$ GQA/MLA）、归一化（Post-LN $\rightarrow$ Pre-RMSNorm）、激活函数（ReLU $\rightarrow$ SwiGLU）。理解这四个插槽，就理解了 LLM 架构史的八成（详见第 3、5 章）；2024 年后的 MoE 与 SSM 混合架构，也只是在这副骨架上做“稀疏化”与“线性化”的深加工。

3 Transformer 深度剖析：注意力机制的数学本质

3.1 标准 Transformer 架构

一个完整的 Transformer Block 包含**两个子层**：多头自注意力 + 前馈网络，每个子层都有**残差连接**和**归一化**：

图 4 展示了这一结构。这里补充一个关键视角——**FFN 是模型的“键值记忆体”**：研究 (Geva et al., 2021) 表明，FFN 的第一层相当于一组“模式检测键”（检测输入中的某种语义模式），第二层是与之配对的“知识值”（把该模式映射为下一个词的倾向）。模型的成块事实知识（人物、API、历史事件）大量存储在这一层层的键值对里——这解释了三件事：为什么 FFN 占参数大头、为什么 MoE（第 5 章）改造的是 FFN 而非注意力、以及为什么“知识编辑”研究（如 ROME/MEMIT，定位并改写 FFN 中的特定键值对）瞄准的也是 FFN。相应地，**注意力层负责“沟通”**：在 token 之间搬运与组合信息（指代、对齐、检索），两个子层一个管“存储”一个管“路由”，缺一不可。

三个现代变体值得注意：(1) *Pre-Norm*——先归一化再做子层运算，原始 Transformer 使用 Post-Norm，而现代 LLM 几乎全部采用 Pre-Norm，因为梯度可沿残差通




图 4: 现代 decoder-only Transformer Block (Pre-Norm 结构): 每个子层先归一化再计算, 残差连接提供无衰减的梯度“高速公路”; 整个 Block 以 $\times N$ 堆叠, 末端 LM Head 将隐状态映射回词表。

路近乎无衰减地回传, 训练显著更稳; (2) *RMSNorm* 替代 *LayerNorm*——省去均值中心化计算, 数值上更鲁棒; (3) *FFN* 膨胀比——前馈层通常把维度扩张至 $2.7\text{--}4\times$ 隐藏维度 (LLaMA 取 $\frac{8}{3}\pi d$ 以配合 SwiGLU 的三路矩阵), FFN 往往占全模型 $\frac{2}{3}$ 以上的参数, 是“知识存储”的主要载体, 也是 MoE (第 5 章) 改造的对象。

3.2 自注意力机制：数学细节

3.2.1 单头注意力

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

- Q, K, V 形状: (batch, seq_len, d_k)
- $QK^\top$ 形状: (batch, n , n)——这就是 $O(n^2)$ 复杂度的来源
- $\sqrt{d_k}$ 缩放: 防止点积值过大导致 softmax 饱和 (当 d_k 大时, $q \cdot k$ 的方差为 d_k , 除以 $\sqrt{d_k}$ 使方差归一化)
- 时间复杂度: $O(n^2 \cdot d)$
- 空间复杂度: $O(n^2)$ (注意力矩阵)




图 5: 自注意力计算流水线: 一个输入经三路投影产生 Q, K, V ; 相似度经缩放与 Softmax 归一化后对 V 加权求和得到单头输出; h 个头并行执行后拼接、经 W^O 融合回残差流。

3.2.2 多头注意力

$$\text{MHA}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

$$\text{head}_i = \text{Attention}(XW_i^Q, XW_i^K, XW_i^V)$$

直觉理解: 把注意力看作一次软检索——每个 token 的 q 向量是“我要找什么”，所有 token 的 k 向量是“我能提供什么标签”， v 向量是“我的实际内容”。 QK^T 计算所有标签匹配度，softmax 将其归一化为注意力分布，最后对内容 V 做加权平均。整个机制不含任何显式规则，全部结构关系由训练中的梯度自动塑造。

每个头在不同子空间中学习不同的注意力模式：

- 某些头关注**语法结构**（如主谓宾关系）
- 某些头关注**语义关系**（如同义替换、上下位）
- 某些头关注**指代消解**（“它”指代谁）
- 某些头关注**位置模式**（如相邻 token）

注意力可视化的发现

研究（Vig, 2019; Wang et al., 2022）表明：GPT-2 中约 10% 的注意力头可被归类为“归纳头”（induction heads），它们学会了“当看到与上文相同 token 出现时，预测上文的下一个 token”。这是模型习得长距离模式匹配的关键机制。

3.3 位置编码

Transformer 本身不包含位置信息，需要外部注入。下表汇总了主要方案：

RoPE（旋转位置编码）原理——这是 LLM 领域最重要的创新之一：

方法	原理	使用模型
绝对位置编码	正弦/余弦函数	原始 Transformer
可学习位置编码	直接学习位置向量	BERT、GPT-2
RoPE	将位置编码为旋转矩阵	LLaMA、Qwen、Mistral
ALiBi	注意力分数加距离偏置	MPT、BLOOM
NTK-aware scaling	外推 RoPE 到长序列	LLaMA-2-128K
YaRN / NTK-by-parts	分段外推	2025 年主流长上下文方案

表 4: 位置编码方案对比

对 query 和 key 向量，按位置 m 施加**旋转矩阵**：

$$f(q, m) = R_m \cdot q, \quad R_m = \begin{pmatrix} \cos m\theta_1 & -\sin m\theta_1 \\ \sin m\theta_1 & \cos m\theta_1 \end{pmatrix} \oplus \dots$$

其中 $\theta_i = 10000^{-2i/d}$ 是频率参数， $\oplus$ 表示块对角拼接。

这样注意力分数自然包含了**相对位置**信息：

$$q_m^\top k_n = q^\top R_{n-m}^\top R_n k = q^\top R_{n-m} k$$

RoPE 的优势

1. **天然支持相对位置**：注意力分数只依赖 $n - m$
2. **推理时 KV Cache 友好**：不需要修改已缓存的 K
3. **可外推**：通过调整 θ_i 或插值即可扩展上下文长度
4. **无额外参数**：纯数学变换，不增加模型大小

长上下文外推是 RoPE 的工程延伸：模型在 4K 上下文上训练后要在 128K 上使用，直接外推会导致注意力分数在训练时从未见过的相位组合上“失准”。NTK-aware scaling 通过降低基频 θ_i （等效拉伸频谱）让远距位置落在训练分布的邻域内；YaRN (NTK-by-parts) 进一步对高/低频分段处理，兼顾局部精度与长程外推，已成为 2025 年 128K–1M 长上下文方案的常用组件——配合训练时的长文本课程（curriculum）使用，效果最佳。

3.4 解码器 vs 编码器

因果掩码（Causal Mask）确保 token t 只能看到 $\leq t$ 的信息：

$$M_{ij} = \begin{cases} 0 & \text{if } i \leq j \\ -\infty & \text{if } i > j \end{cases}$$

特性	编码器 (BERT)	解码器 (GPT/LLaMA)	编码-解码 (T5)
注意力	双向	因果 (Causal)	编码双向 + 解码因果
预训练目标	MLM	Next Token	Span Corruption
适用场景	分类、检索	生成、对话	翻译、摘要
推理速度	一次前向	自回归逐 token	两阶段
LLM 主流	–	✓	–

表 5: 三种 Transformer 变体对比

在 softmax 中， $e^{-\infty} = 0$ ，实现了严格的单向信息流。

因果掩码看似限制了信息流，实则带来两个关键工程红利：其一，训练时同一 prompt 的所有位置可以并行计算（每个位置只依赖前文，互不冲突），一次前向即产生 T 个训练样本；其二，推理时位置 t 的 Key/Value 只依赖前文，因此可缓存复用——这正是 KV Cache 的合法性来源（详见第 6 章）。可以说，自回归 LLM 的“可并行训练 + 可增量推理”这一看似矛盾的组合，统一由因果掩码保证。

4 大语言模型（LLM）训练流水线

LLM 的训练通常分为三个核心阶段：预训练 → 监督微调 → 人类对齐。下面逐一展开。




图 6: LLM 训练流水线三阶段：成本与数据规模逐级递减，而“行为塑造”的杠杆逐级增大；虚线反馈构成持续迭代的数据飞轮。

图 6 概括了本章结构。三个阶段的成本结构截然不同：预训练吃掉 95% 以上的总算力，却只决定模型的“智力上限”；SFT 与对齐花费不到 5% 的算力，却几乎完全决定模型的“可用性”——这种不对称性是理解大模型产业分工的钥匙（基座厂商与后训练/应用团队的价值链切分）。

4.1 阶段一：预训练 (Pre-training)

目标：学习语言的统计规律和世界知识。

数据构成：

- 互联网爬取文本 (CommonCrawl 等, 数万亿 token)
- 书籍、学术论文、代码 (GitHub)
- 高质量语料筛选：去重 (MinHash/SimHash)、质量过滤、毒性过滤
- **数据配比至关重要：**通用网页 50–70%，代码 10–20%，书籍/学术 10–20%

数据工程是预训练的第一竞争力。一个典型的工业级数据管线包含五个环节：(1) 原始获取——CommonCrawl 等来源按快照 (月级) 批量下载，单次快照可达数百 TB；(2) 解析清洗——HTML 解析为纯文本，剔除导航栏、脚本、乱码；(3) 质量过滤——用小分类器或启发式规则 (长度、符号比、重复 n-gram 占比) 打分，各家经验是删掉一半低质数据后效果更好；(4) 去重——文档级去重 (精确哈希) + 段落/句级近似去重 (MinHash + LSH, 典型保留 85–95%)，重复数据会诱导模型“背诵”而非“理解”；(5) 安全与合规——毒性过滤、PII 脱敏、版权排除列表。DeepSeek-V3 报告约 14.8T token 训练语料，其中合成与代码占比显著提升——数据的边际价值在 2024 年后已超过参数规模，这已成为行业共识。

两个常被低估的细节：其一，数据配比是最大的超参数——通用网页、代码、书籍、学术、多语言的比例直接决定模型的能力画像 (代码数据提升的不只是编程，还有逻辑推理；多语言数据的清理质量决定“人格”是否统一)，头部团队的做法是在训练中周期性跑评测、动态调整配比 (data curriculum)；其二，*tokenizer* 决定语言经济学——以 Qwen 的 15 万词表为例，中文约 1.5–2 字/token，而英文约 0.25 词/token，同样的上下文窗口里中文可容纳的信息量因此翻倍级差异；中文语料还面临“清洗后存量明显小于英文”的事实，这推动国内团队更早转向合成数据与多语言混合训练。

训练目标：Next Token Prediction (因果语言建模)，即

$$\max_{\theta} \mathbb{E}_{(x_1, \dots, x_T)} \left[\sum_{t=1}^T \log P_{\theta}(x_t | x_{<t}) \right]$$

4.1.1 分布式训练策略

大规模 LLM 训练需要数千张 GPU 协同工作，核心策略包括：

硬件与软件栈：

- **硬件：**NVIDIA H100/H200/B200、Google TPU v5p/v6、自研 ASIC
- **通信：**NCCL、NVLink、GPUDirect RDMA
- **软件：**PyTorch DDP / FSDP / DeepSpeed / Megatron-LM / JAX

策略	原理	典型框架
数据并行 (DP)	每张卡独立梯度, AllReduce 同步	PyTorch DDP、FSDP
张量并行 (TP)	单个矩阵拆到多卡	Megatron-LM
流水线并行 (PP)	不同层放在不同卡上	GPipe / 1F1B 调度
序列并行 (SP)	长序列拆分	Ring Attention
ZeRO 优化	分片优化器状态/梯度/参数	DeepSpeed ZeRO-1/2/3
3D/4D/5D 混合	DP + TP + PP (+ SP + EP)	生产级训练标配

表 6: 分布式训练策略

如何组合这些并行维度是大规模训练的核心设计决策，判据是通信频率与拓扑匹配：

- 张量并行通信最频繁（每层前向/反向各需一次 allreduce/allgather），必须放在 NVLink 域内（单机 8 卡）；
- 流水线并行只在 micro-batch 边界通信,通信量小,适合跨节点 (InfiniBand/RoCE); 气泡 (bubble) 用 1F1B + 足够 micro-batch 数压制；
- 数据并行每步一次梯度同步，放最外层横向扩展吞吐；ZeRO/FSDP 在其内部进一步分片显存；
- 专家并行（MoE 专用）按专家分片，配合 all-to-all 通信，是第 5 章 MoE 训练的必备维度。

生产级训练典型拓扑是：节点内 $TP=8 \times$ 节点间 $PP=4-8 \times$ 最外层 $DP/ZeRO$ ，即 3D/4D/5D 混合并行。以 70B 模型为例，BF16 参数约 140GB，Adam 状态再乘 3 倍以上——单卡 80GB 远放不下，TP 切参数 + ZeRO 切状态是标准解法。

2025 年的效率标杆：DeepSeek-V3 在 2048 块 H800 上以 *DualPipe* 双向流水线（前向/反向计算与 all-to-all 通信深度重叠，几乎消除流水线气泡）、FP8 混合精度与节点受限路由的组合，把 14.8T token 的训练压缩到约 2.79M GPU·hours——印证了架构-系统协同设计比单纯堆卡更能决定训练经济学。

4.1.2 典型超参数

（GPT-4 级别参考）

- 学习率：~ 3×10^{-4} （cosine decay to 1×10^{-5} ）
- Batch size：~ 4M tokens（通过梯度累积实现）
- 训练步数：数十万步量级（如 Llama 2 70B 以约 4M token 的全局 batch 训练约 2T token，对应数十万步）
- 精度：BF16 前向/反向 + FP32 主权重

- Warmup: 2000–10000 步
- Weight decay: 0.1
- Gradient clip: $\|g\| \leq 1.0$

4.1.3 容错与检查点

训练 100B+ 参数模型通常需要 3–12 个月，**容错机制**至关重要：

- **分片式 checkpoint**：每个 rank 只持久化本地分片（参数、优化器状态、数据加载器游标），恢复时 AllGather 重建全局状态，避免全量镜像的单点与带宽瓶颈
- 故障检测与自动恢复（heartbeat + 重试）
- 弹性训练：节点故障时自动重新分配
- 典型频率：每 100–500 步保存一次 checkpoint

4.2 阶段二：监督微调（SFT）

目标：从“补全文本”转向“遵循指令、回答问题”。

数据构造：

- 高质量指令-回答对（数千到数十万条）
- 来源：人工标注、模型蒸馏、规则生成
- 覆盖：问答、代码、翻译、数学、写作、推理**核心原则**：数据质量 $\gg$ 数量（10K 高质量 > 1M 低质量）

SFT 到底教了模型什么是一个值得澄清的问题：主流研究（如 LIMA）支持“SFT 是对齐/格式化，而非灌输知识”——能力几乎全部来自预训练，SFT 教会的是调用能力的接口（听懂指令、组织答案、切换角色）。因此 SFT 数据的关键不是数量而是多样性-质量-难度的三角平衡：覆盖足够多的任务形态（防止“会 A 不会 B”）、每条都经人工或强模型把关（防止学坏习惯）、并保留足够比例的复杂推理样本（防止能力退化）。2024 年后，SFT 数据中合成数据的占比持续上升（模型蒸馏 + 人工审核的流水线），“用强模型造数据、以人工守边界”成为标准做法；但纯合成数据的“分布收窄”风险（模型输出越来越像训练它的模型）也促使各家保留真实用户 query 与专业作者样本。

自动数据构造技术：

- **Self-Instruct**：让模型自己生成指令
- **Evol-Instruct**：迭代进化指令复杂度（简单 $\rightarrow$ 复杂）
- **拒绝采样**：生成 k 个回答，选最好的

训练配置：

- 学习率： $10^{-5} \sim 5 \times 10^{-5}$ （比预训练低 10–100 倍）
- Epoch：1–3
- 损失只计算**回答部分**（prompt 部分 mask 掉）
- 可选：LoRA 低秩适配（ $r = 16\text{--}64$ ，仅训练 $\sim 1\%$ 参数）

LoRA 的数学形式：冻结原权重 $W \in \mathbb{R}^{d \times k}$ ，旁路一个低秩增量

$$W' = W + \Delta W = W + BA, \quad B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k)$$

可训练参数量从 dk 降至 $r(d+k)$ （ $r = 16$ 时约为原来的 $\frac{1}{20}$ ）。经验上 LoRA 应加在注意力的 W^Q, W^V （甚至 W^K, W^O ）而非 FFN 上效果更稳。其工程价值在于：同一基座可维护多个低成本领域适配器（医疗、法律、代码），且推理时可合并权重、零额外延迟。QLoRA 进一步把基座量化到 4-bit（NF4）+ 分页优化器，使 65B 模型可在单张 48GB 卡上微调——这是个人研究者参与大模型微调的起点。

4.3 阶段三：人类对齐（Alignment）

4.3.1 RLHF：基于人类反馈的强化学习

经典三组件架构：

SFT 模型（Policy） $\rightarrow$ Reward Model（人类偏好训练） $\rightarrow$ PPO Agent（策略优化）

步骤 1：收集偏好数据

给定同一个 prompt x ，模型生成 k 个回答 $\{y_1, \dots, y_k\}$ ，人类排序选出最优 y_w 和最差 y_l 。

步骤 2：训练奖励模型

使用 Bradley-Terry 模型：

$$P(y_w \succ y_l \mid x) = \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$$

损失函数：

$$\mathcal{L}_{\text{RM}} = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))]$$

步骤 3：PPO 优化策略

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(y|x)} [r_\phi(x, y) - \beta \cdot \text{KL}(\pi_\theta \parallel \pi_{\text{ref}})]$$

- r_ϕ ：奖励模型给出的分数
- β ：KL 约束强度（典型值 0.01–0.2）
- π_{ref} ：SFT 模型（防止偏离太远）

RLHF 的工程挑战

- 1. 需要同时维护 4 个模型：Policy、Reference、Reward、Value Critic
- 2. 显存需求是 SFT 的 4 倍
- 3. 训练不稳定，超参数（学习率、 β 、GAE λ ）非常敏感
- 4. 奖励模型容易被 “hack”：模型生成极端文本骗取高分
- 5. 离线偏好数据存在分布偏移

4.3.2 DPO：直接偏好优化

2023 年提出，去掉了 Reward Model，直接从偏好对优化策略：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x,y_w,y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

DPO 的直觉：注意 $\beta \log \frac{\pi_{\theta}(y|x)}{\pi_{\text{ref}}(y|x)}$ 恰好是 RLHF 目标下隐式奖励的闭式解（RLHF 的最优策略满足 $\pi^*(y|x) \propto \pi_{\text{ref}}(y|x) e^{r(x,y)/\beta}$ ，反解即得 $r = \beta \log \frac{\pi^*}{\pi_{\text{ref}}} + \text{const}$ ）。因此 DPO 相当于把奖励模型 “吸收” 进策略网络：不再单独训练 RM，而是直接以 “相对参考模型的隐式偏好差” 为监督信号优化策略。代价是它只能利用离线偏好对，无法在线采样——当分布偏移大时效果弱于在线 RL（如 GRPO），这也是 2025 年 “在线 RL 回归” 趋势的背景（见第 7 章 DeepSeek-R1）。

方法	核心思想	优势	劣势
PPO	经典 RL + RM	灵活、表达力强	不稳定、显存大
DPO	无 RM，直接优化	简单、稳定、省显存	表达力稍弱
IPO	DPO 改进	避免过拟合	—
KTO	只需二元反馈	不需成对数据	信息量较少
ORPO	SFT + 偏好两合一	简化流程	—
SimPO	长度归一化	减少长度偏差	—
RLOO	无 Critic 的 RL	方差更低	—
GRPO	组相对策略优化	DeepSeek 2025	—

表 7: 对齐方法对比

4.3.3 Constitutional AI (Anthropic)

用 “宪法”（一组原则列表）指导模型**自我批评**：

- 1. 模型生成回答
- 2. 模型根据宪法原则自我批评

3. 模型根据批评修改回答

4. 用修改后的数据做 SFT

RLAIF (RL from AI Feedback) 进一步用 AI 反馈替代人类反馈，大幅降低成本。

对齐的三条经验规律值得记录。第一，对齐税 (alignment tax) 真实存在但可控：过度保守的 RM 会让模型变得过度谨慎、拒答泛滥，工程上用“有用性/无害性”双奖励加权来平衡。第二，Goodhart 定律是 RLHF 的宿命：RM 只是人类偏好的代理指标，优化久了必然出现 reward hacking (谄媚、冗长、堆砌格式)，因此 RM 需要持续用新鲜偏好数据再训。第三，可验证奖励 (RLVR) 正在接管推理域：数学有标准答案、代码能跑测试，这类任务直接用规则判分 (第 7 章 R1 的做法)，绕开了 RM 的全部毛病——“有标准答案的交给规则，没有的才交给人类”。

4.4 持续学习与更新

- **灾难性遗忘**：新知识覆盖旧知识
- **解决方案**：混合新旧数据回放、LoRA 增量适配、弹性权重固化 (EWC)
- **持续预训练 (CPT)**：在特定领域数据上继续预训练
- **RAG (检索增强生成)**：外挂知识库，不修改权重

四种“更新知识”手段的选型判据：

- **RAG**：知识更新快 (改库即可)、可溯源、适合私有/高频变化知识；缺点是受检索质量制约，跨文档推理弱；
- **LoRA/CPT**：把领域风格与隐性知识内化进权重，推理时无需检索、延迟低；代价是每更新一轮需重新训练与评估；
- **全量 CPT**：领域能力上限最高 (如医疗、法律、代码专精模型)，但成本高、易伤通用能力，需混入通用数据“回防”。

生产系统的常见组合是 RAG (事实层) + SFT/LoRA (行为层)：让模型“知道怎么做”靠微调，“知道当前事实”靠检索——两者正交、可叠加。

5 前沿架构创新

5.1 混合专家 (Mixture of Experts, MoE)

核心思想：FFN 层拆分为 N 个“专家”，每个 token 只激活 Top- K 个专家，实现稀疏激活。

细粒度专家 + 共享专家的设计逻辑值得展开。传统 MoE (如 Mixtral) 用 8 个大专家选 2 个，组合数有限 ($C_8^2 = 28$)；DeepSeek-V3 把专家切细到 256 个、每个专家更




图 7: MoE 层工作机制：Router 为每个 token 打分并选出 Top-K 个专家，仅被选中的专家（橙色）参与计算，输出按门控权重 α_i 加权合并；共享专家每 token 恒激活，负责“通用知识”。

小，选 8 个的组合数达 10^{14} 量级——同样的计算预算下，知识可以按更细的粒度组织（“数学-积分-符号处理”这样的专项专家成为可能）；而 1 个共享专家恒定激活，承担所有 token 都需要的通用计算，让路由专家可以更“偏科”。代价同样明显：全部专家必须常驻显存（671B 参数即使只激活 37B，加载与分布式缓存的仍是全量），MoE 推理服务对显存容量（而非算力）更敏感，这是 MoE 部署经济学与稠密模型的本质差异；训练侧则引入专家并行（EP）与 all-to-all 通信，是 4D/5D 并行中最难调的一维。

$$\text{MoE}(\mathbf{x}) = \sum_{i \in \text{Top-K}} \alpha_i \cdot \text{Expert}_i(\mathbf{x}), \quad \alpha_i = \text{softmax}(\text{Router}(\mathbf{x}))_i$$

模型	总参数	激活参数	专家结构
Mixtral 8×7B	46.7B	12.9B	8 专家 / 激活 2
Qwen3-235B-A22B	235B	22B	128 专家 / 激活 8（无共享专家，KV 头 4）
DeepSeek-V3	671B	37B	256 路由专家 / 激活 8（+1 共享专家）
Llama 4 Scout	~109B	17B	16 专家 / 激活 1
Kimi K2	~1T	32B	384 专家 / 激活 8（+1 共享专家）
GPT-4（估计）	1T+	100–200B	未公开

表 8: MoE 模型参数规模（总参数决定“知识容量”，激活参数决定单 token 计算成本）

为什么 MoE 成为旗舰模型主流架构：核心是解耦“知识容量”与“单 token 计算量”。稠密模型中，参数规模直接绑定推理成本；MoE 让参数量（可存储的知识）继续扩张，而每个 token 只付费激活的 K 个专家。DeepSeek-V3 把这一点推到极致：671B 总参数中仅 37B 参与前向，训练成本约 **2.79M H800 GPU·hours**（折合约 **\$5.5M**）——以 2024 年底的价格训练出对标 GPT-4 级别的模型，直接改写了大模型的经济学。

路由策略：Top- K 路由 ($K = 2$ 最常见)、Noisy Top- K (加噪声鼓励探索)、Expert Choice (专家选 token)。

谱系：MoE 并非新事物——2017 年 Shazeer 等的稀疏门控 LSTM 层即其雏形；GShard (2020) 与 Switch Transformer (2021, 1.6T 参数) 首次将其带入 Transformer 大规模训练；Mixtral 8×7B (2024) 证明 MoE 可以兼顾开源与工程友好；DeepSeek-V3、Qwen3 与 Kimi K2 (2025) 则把“细粒度专家 + 共享专家 + 无辅助损失/精细负载均衡”打磨成旗舰标配。

负载均衡辅助损失 (Switch Transformer 形式)： $\mathcal{L}_{\text{aux}} = \alpha \cdot N \cdot \sum_j f_j \cdot P_j$ ，其中 f_j 是第 j 个专家被选中的 token 频率、 P_j 是路由器分配给它的平均概率——最小化该损失会促使负载 $f_j \rightarrow 1/N$ 均匀。

DeepSeek-V3 的 MoE 创新 (细粒度专家 + 共享专家 + 无辅助损失均衡)：

- **无辅助损失负载均衡：**为每个专家引入偏置项 b_i ，它只参与 Top- K 路由的选择、不进入门控加权值，并按负载动态增减——在不引入“为平衡而牺牲质量”的梯度干扰的前提下实现均衡；辅以序列级互补辅助损失与**节点受限路由** (每个 token 的专家限定在至多若干节点内，压低 all-to-all 通信量)；
- **Multi-Token Prediction (MTP)：**附加一个轻量 MTP 模块同时预测下下个 token，密集训练信号改善表征；推理时该模块可整体丢弃，或直接充当自草拟的推测解码器 (见第 6 章)；
- **训练成本：**约 2.79M H800 GPU·hours (约 \$5.6M, 2024 年 12 月技术报告口径)，且 **FP8 混合精度**首次在 671B 规模全程使用。

5.2 注意力机制变体

5.2.1 GQA (Grouped Query Attention)

Q 有 h 个头， KV 有 g 个头 ($g < h$)，多个 Q 头共享一个 KV 头。KV Cache 减少 h/g 倍 (典型 4-8×)，质量几乎不降。用于 LLaMA 2 70B、Mistral 7B、Gemma 2。

算一笔显存账： $\text{KV Cache 大小} = 2(K/V) \times L \times n_{\text{kv}} \times d_h \times T \times \text{batch} \times \text{bytes}$ 。以 LLaMA-2 70B 为例 (80 层、64 个 Q 头、每头 128 维、FP16)，单条 4K 上下文序列的 KV Cache 为 $2 \times 80 \times 64 \times 128 \times 4096 \times 2 \text{ B} \approx 10.7 \text{ GB}$ ——batch 32 时约 343GB，远超模型权重本身 (约 140GB)。GQA 将 KV 头从 64 降到 8，同条件下降到约 43GB (单序列约 1.3GB)，恰好回到“可服务”量级。LLaMA-2 技术报告的结论是：70B 上 GQA-8 的建模质量与 MHA 基本持平，而解码吞吐向 MQA 看齐——这一“近乎免费”的压缩是 GQA 成为 2024 年后几乎所有新模型默认配置的原因。

5.2.2 MLA (Multi-head Latent Attention)

DeepSeek-V2/V3 创新，将 K、V 联合压缩到低维隐空间：

$$\hat{K} = W_{KV}^D \cdot (W^C \cdot \mathbf{x}), \quad \hat{V} = W_{KV}^U \cdot \hat{K}$$

KV Cache 压缩比比 GQA 高 **5–10 倍**。关键洞察：K 和 V 信息冗余度高，可共享压缩空间。

直觉展开：MLA 观察到，对推理成本起决定作用的不是“KV 有多少个头”，而是“每个 token 需要缓存多少维”。于是把 (K, V) 联合压缩到一个低维隐向量 $c_{KV} \in \mathbb{R}^{d_c}$ (DeepSeek-V2 中 $d_c = 512$ ，而 LLaMA2-70B 每 token 的 KV 是 $64 \times 2 \times 128 = 16384$ 维)，缓存 c_{KV} (512 维) 加少量解耦 RoPE 键 (64 维) 替代缓存全部 K/V——DeepSeek-V2 官方报告生成阶段 KV Cache **降低 93.3%**，推理成本同步大幅下降。位置信息则通过独立的“解耦 RoPE”注入，避免压缩破坏旋转位置结构。这一设计证明了架构级省显存比系统级省显存（量化、分页）更根本——它改变了“多大批量可服务”的经济学上限。

5.2.3 滑动窗口注意力

Mistral 7B：窗口大小 4096，每 4 层一次全局注意力。显存 $O(\text{window})$ ，长序列推理友好，但窗口外信息丢失。

5.2.4 线性注意力与状态空间模型

Linear Transformer：用核函数 ϕ 近似 softmax，复杂度 $O(nd^2)$ 。

Mamba / Mamba-2：选择性状态空间模型 (SSM)， $O(n)$ 复杂度：

$$h_t = \bar{A} h_{t-1} + \bar{B} x_t, \quad y_t = C h_t$$

长序列推理极快，但表达能力可能不如标准注意力。2025 趋势：Mamba-Transformer 混合架构。

Mamba 的关键创新是“选择性” (selectivity)：早期线性 SSM（如 S4）的状态转移矩阵 A, B, C 是与输入无关的常量，等价于一个固定滤波器，无法实现“看内容决定记什么”。Mamba 让 A, B, C 成为当前输入 x_t 的函数（选择性扫描，selective scan），并以硬件感知的并行 scan 算法实现——兼顾 RNN 的 $O(1)$ 递推推理与 GPU 上的并行训练。实际部署中的共识是混合架构：用少量注意力层负责“精确检索”（注意力是精确查找表，SSM 是压缩记忆），如 Jamba、Zamba 以及 2025 年 NVIDIA Nemotron-H 等“注意力 + SSM 交替”设计，在长上下文成本与检索精度之间取得平衡。

回看本节，KV 侧的三代优化构成一条清晰的演进线： MQA （全部 Q 头共享 1 个 KV 头，省到极致但质量受损） $\rightarrow GQA$ （分组共享，质量与开销折中） $\rightarrow MLA$ （把 KV 联合压缩进低维隐空间，本质是对 KV 做“表示学习”）。每一代都在回答同一个问题——“KV 里到底有多少信息是真正必要的？”——并给出更激进的答案；配合量化与分页（第 6 章），架构级与系统级的省显存手段相互正交、可以叠加。

5.3 代表性架构创新

模型	核心创新	亮点
DeepSeek-V2	MLA + 细粒度 MoE	KV Cache 压缩 93.3%
DeepSeek-V3	无辅助损失 MoE + MTP + FP8	约 \$5.6M 训练 671B
DeepSeek-R1	纯 RL 推理 + GRPO	无 CoT 标注涌现推理
Kimi K2	1T 级 MoE 全量开源	开源模型榜第一 (LMArena)
Qwen3-235B-A22B	MoE + 混合思考/思考预算	128 专家/激活 8, Apache 2.0
Gemini 3 Pro	原生多模态 + Deep Think	LMArena 首破 1500 Elo
Gemini 3.7 (2026, 据报道)	Agentic 多 Agent	多 Agent 数学/工程
Llama 4	大规模 MoE + 长上下文	开源旗舰 (评测有争议)

表 9: 2024–2026 代表性架构创新

架构创新的一般方法论：先在小模型上验证（数天内完成对比实验）、再放大到旗舰规模——Chinchilla 与 DeepSeek 的所有架构决策都遵循这一“小模型先导”原则，这也是 μP 类超参迁移技术（第 10 章）的价值所在。评价一项架构创新，看三件事：帕累托改进（同质量下成本是否下降，而非仅“分数是否更高”）、硬件亲和性（是否匹配显存带宽/互联拓扑的约束）、工程可落地性（推理引擎多快能支持）。2024–2026 年的赢家——MoE、GQA/MLA、MTP、FP8——全部是这三条的优等生；而一些“分数好看”但硬件不友好的设计（如某些双向注意力变体）则停留在论文阶段。

6 推理优化

6.1 推理瓶颈分析

LLM 推理分两个阶段，瓶颈完全不同：

阶段	特征	瓶颈类型	优化方向
Prefill	处理整个 prompt	计算密集	FlashAttention、算子融合
Decode	逐 token 生成	访存密集	KV Cache 优化、推测解码

表 10: 推理两阶段瓶颈

分析工具：算术强度 (Arithmetic Intensity, FLOPs/Byte)。Prefill 阶段，一个长度为 n 的 prompt 前向时，权重只需读取一次却参与 n 次运算，算术强度 $\propto n$ ，轻松超过硬件的“计算/访存平衡点”（如 H100 BF16 约 989 TFLOPS/3.35 TB/s $\approx$ 295 FLOP/Byte），

属于计算受限；Decode 阶段每个 token 都要把全部权重重新读一遍，算术强度 ≈ 1 （权重为主时），远低于平衡点，属于访存受限。这一判据直接推出两条优化主线：Prefill 拼算力（FlashAttention、算子融合、FP8），Decode 拼带宽（KV Cache 压缩、量化、推测解码“一次读权重出多个 token”）。




图 8: LLM 推理系统全景：Prefill 与 Decode 瓶颈不同、优化路径不同，中间的 KV Cache 是两条路径的交汇点；底座是所有主流引擎共享的服务层技术栈（详见 6.2-6.6 节）。

衡量推理服务的四个指标是后续所有优化的靶子：TTFT（Time To First Token，首 token 延迟，主要由 Prefill 决定，交互体验的第一印象）、TPOT（Time Per Output Token，单 token 生成间隔，主要由 Decode 决定，决定“打字机”的流畅度）、吞吐量（tokens/s，决定单位算力成本）与并发容量（同时服务的请求数，由 KV Cache 显存余量决定）。四者相互牵制——批越大吞吐越高，但 TPOT 与 TTFT 随之变差；KV Cache 压得越省并发越高，但可能牺牲质量。推理系统的全部艺术，就是按照业务 SLO（如“TTFT < 400ms、TPOT < 30ms”）在这四个数字之间找最优工作点。

6.2 KV Cache 优化

显存占用：Size = $2 \times L \times n_{kv} \times d_{kv} \times n_{batch} \times n_{bytes}$

优化手段：

- GQA / MLA：减少 KV 头数（4-10× 压缩）
- PagedAttention (vLLM)：分页管理，减少碎片
- KV Cache 量化：FP16 → INT8 → INT4
- Sliding Window：只保留最近窗口
- H₂O / StreamingLLM：保留高注意力 token
- Prefix Caching：共享 system prompt 的 KV Cache

6.3 量化技术

精度	显存占比	质量损失	场景
FP16 / BF16	100%	无	服务器
FP8	50%	<0.5%	H100 原生支持
INT8	50%	<1%	边缘部署
INT4	25%	1–3%	移动端

表 11: 量化精度对比

主流量化算法及其思路：

- **GPTQ**：基于 Hessian 二阶信息的离线逐层最优量化——逐列量化后用已量化列修正剩余列，误差累积可控；
- **AWQ**：激活感知——统计输入激活幅度，对“显著通道”施加保护性缩放再量化，避免异常值（outlier）主导误差；
- **SmoothQuant**：针对激活值的量化难题，把激活的异常难度“迁移”一部分到权重上（逐通道等价变换），使 W8A8 同时可行；
- **GGUF / llama.cpp**：面向 CPU/混合推理的分块量化格式，支持 2–8 bit 混合精度与 Q4/Q5 档位，是端侧生态的事实标准。

选择经验：服务端大流量场景优先 FP8/W8A8（质量损失 <1%，且 H100 原生支持、算力翻倍）；边缘/移动端用 INT4/AWQ；CPU 用 GGUF。

6.4 推测解码 (Speculative Decoding)

小模型快速草拟 k 个 token，大模型一次验证：

$$\alpha = \min\left(1, \frac{P_{\text{target}}(t \mid \text{ctx})}{P_{\text{draft}}(t \mid \text{ctx})}\right)$$

为什么质量无损：上面的 α 正是接受-拒绝采样的接受概率——被拒绝的 token 按修正分布 $\propto \max(0, P_{\text{target}} - P_{\text{draft}})$ 重新采样，可以严格证明整个过程的输出分布与直接对目标模型采样**完全一致**。这就是推测解码“免费加速”的数学保证：加速来自“一次权重读取验证多个 token”，而非任何近似。

工程上期望加速比 $2-3\times$ （取决于草拟模型与目标模型的分布接近程度）。草拟模型的选择有三条路线：小模型（经典方案）、同模型多头（Medusa 在主干上加解码头并行猜多 token、Self-Draft）、特征级自草拟（EAGLE/EAGLE-2 利用倒数第二层隐状态直接生成候选，2025 年主流）。变体还有 Lookahead Decoding（Jacobi 迭代，无需任何草拟模型）。

6.5 推理引擎与系统优化

引擎	核心特点
vLLM	PagedAttention + 连续批处理
TensorRT-LLM	NVIDIA 专用，极致优化
SGLang	结构化输出加速、RadixAttention
llama.cpp	CPU/边缘推理，GGUF 格式
MLX	Apple Silicon 优化

表 12: 主流推理引擎

关键系统优化：

- **Continuous Batching**：请求完成即释放，新请求随时插入，吞吐提升 2-5×
- **FlashAttention 3**：IO-aware 分块 + Hopper TMA/WGMMA，注意力 2-4× 加速
- **算子融合 / CudaGraph**：减少显存读写和 CPU-GPU 同步
- **结构化输出**：Guided Decoding / JSON Mode (Outlines、XGrammar)

两个核心机制展开：

FlashAttention 的关键洞察是注意力慢的根因不在计算而在显存读写：朴素实现要把 $n \times n$ 的注意力矩阵写入 HBM 再读回，显存访问量 $O(n^2)$ 。FlashAttention 把 Q, K, V 切成驻留 SRAM 的块 (tile)，在片上完成“块内 softmax + 累加”，并用 online-softmax 技术避免保存完整注意力矩阵——复杂度不变（仍是 $O(n^2)$ 计算），但显存降到 $O(n)$ 、访存降至理论下界，实测 2-4× 加速。FlashAttention-2 改进了块内并行划分，FlashAttention-3 利用 Hopper 的 TMA/WGMMA 异步流水再提速。

Continuous Batching (连续批处理 / in-flight batching) 改变了推理服务的基本调度单位：从“静态 batch 全部完成才能出结果”变为“每个 decode step 动态重组 batch”——先完成的请求立即出队、新请求即刻插入。配合 KV Cache 分页 (PagedAttention, 类比操作系统虚拟内存：物理块不要求连续、逻辑视图连续)，显存碎片从 60%+ 降至 4% 以下，系统吞吐提升 2-5× 以上。这两项技术是 vLLM 成为开源推理事实标准的核心，2024 年后已成为所有主流引擎的标配。

引擎竞争格局 (2026)：vLLM 与 SGLang 双雄并立——前者生态最全、硬件覆盖最广，后者以 RadixAttention 前缀复用与结构化输出见长；TensorRT-LLM 是 NVIDIA 官方的极致性能路线（编译式优化，灵活性换速度）；llama.cpp 统治 CPU/端侧 (GGUF 生态)，MLX 服务 Apple Silicon。值得关注的是**模型厂商反向开源基础设施**的趋势：DeepSeek 2025 年初陆续开源 FlashMLA (MLA 专用注意力核)、DeepGEMM (FP8 GEMM 库)、3FS (训练数据存储) 等组件，把“架构-系统协同设计”的成果回馈社区；

国内则围绕华为 Ascend 等国产算力形成 vLLM-Ascend、MindIE 等适配层——推理引擎已经成为“模型-硬件”之间的必争中间层。

7 推理模型 (Reasoning Models)

7.1 从 CoT 到 System 2

传统 LLM 是“System 1”——快速、直觉式输出。推理模型引入“System 2”——慢思考、逐步推理。

思维链技术演进：

- **Zero-shot CoT**: “Let’s think step by step”
- **Few-shot CoT**: 提供推理示例
- **Tree of Thoughts (ToT)**: 多路径探索 + 回溯
- **Self-Consistency**: 采样多条 CoT, 投票选答案

范式转变：从“提示技巧”到“训练能力”。2022 年的 CoT 提示属于 System 1 的“外骨骼”——能力上限仍受基座模型制约，且无法在简单任务上关闭。2024 年底 OpenAI o1 的出现标志着推理变成一种训练出来的能力：模型在训练中习得“何时思考、思考多久、如何自我修正”，思考长度成为可配置的资源——这即 **Test-time Compute** (测试时计算)：把原本投入“训练”的算力部分转移到“推理时”，用更多 token 换更高准确率。OpenAI、DeepSeek 均报告了推理 *token* 数与任务难度/准确率的幂律关系，即“扩展定律在时间维度的延伸”：

$$\text{准确率} \propto f(\text{训练算力}) \cdot g(\text{推理算力}), \quad g \text{ 同样近似幂律}$$

这一“第三扩展轴”（参数 N 、数据 D 、推理算力 R ）是 2025–2026 年大模型竞争的主战场（详见第 10 章）。

2025 年的实证注脚：o3 在发布时公布的高算力模式取得 **ARC-AGI 87.5%**（此前两年所有模型长期在 30% 以下徘徊），但单任务成本与时延大幅上升；o4-mini 在 AIME 2025 达到 **99.5% pass@1**，并首次实现推理模型的全工具链调用（搜索、Python、图像生成随思考过程穿插使用）。“Test-time compute 换准确率”由此从论文结论变成可售卖的产品开关（low/medium/high 思考档位），也把“每 token 成本”的定价模型改写为“每任务成本”。

7.2 代表性推理模型




图 9: Test-time Compute 的典型收益曲线（示意）：在对数思考预算下，准确率先呈近似幂律爬升，随后进入饱和区——这决定了“思考预算”产品必须按任务难度动态定价，而非无脑拉满。

模型	核心方法	亮点
OpenAI o1	长 CoT + RL	用户不可见推理过程
OpenAI o3 / o4-mini	可配置思考预算 + 全工具链	ARC-AGI 87.5%；AIME 2025 99.5%
DeepSeek-R1	纯 RL + GRPO + 规则奖励	RL 成本 29.4 万美元，开源
Qwen3	混合思考 + 思考预算	单模型双模：/think 与 /no_think
Gemini Thinking	类 o1 推理	原生多模态推理

表 13: 代表性推理模型

7.2.1 DeepSeek-R1 的核心创新

GRPO (Group Relative Policy Optimization) 是 R1 的关键算法：对同一 prompt 采样一组 G 个回答 $\{y_1, \dots, y_G\}$ ，用组内统计量直接计算相对优势

$$\hat{A}_i = \frac{r_i - \text{mean}(\{r_j\}_{j=1}^G)}{\text{std}(\{r_j\}_{j=1}^G)}$$

再套用 PPO 的 clip 目标 + KL 约束优化策略。与 PPO 的本质区别是不需要 Critic 网络——优势估计由组内对比免费给出，显存占用与工程复杂度大幅下降（PPO 需要同时维护 Policy / Reference / Reward / Critic 四个模型）。在数学、代码等可自动判分任务上，规则奖励恰好提供了 r_i ，使整套流水线摆脱了对人类标注的依赖。

四阶段训练流水线 (R1 技术报告)：

- 1. 冷启动 SFT：用数千条高质量长 CoT 样本教会模型“长思考”的基本行为模式，抑制 R1-Zero 的语言混杂与可读性问题；




图 10: DeepSeek-R1 四阶段训练流水线：橙色虚线是 R1-Zero 的对照路径（验证“纯 RL 涌现推理”）；蓝色实线展示蒸馏路线——小模型无需自己跑 RL，直接继承 R1 的推理模式。

2. **大规模 RL (GRPO)**：用规则奖励在数学/代码/STEM 上强化；

3. **拒绝采样 + SFT**：用 R1 生成并经规则验证的约 80 万条样本（60 万推理 + 20 万非推理）反哺基座重新 SFT——R1 主模型即此产物；

4. **全场景 RL**：在推理数据之外加入有用性/无害性奖励，覆盖通用对话场景。

R1-Zero（跳过冷启动、直接 RL）实验证明推理能力可从基座“涌现”，但出现语言混杂与可读性退化——说明少量冷启动数据仍是塑造“思考风格”的有效手段。

这套流水线的三个要点：其一，**规则奖励替代神经奖励模型**——数学用答案校验、代码用测试用例，从源头规避 reward hacking；其二，训练过程出现教科书级的**涌现行为**——模型自发学会“等等，让我重新检查”“我之前的方法可能有误”式的自我验证、回溯与替代方案探索（R1-Zero 训练曲线上出现标志性的“aha moment”：反思类 token 随训练显著增多，基准准确率同步跳变）；其三，**能力可蒸馏**——把 R1 生成的推理样本直接 SFT 到 Qwen/Llama（1.5B-70B 共 6 个小模型），小模型在数学基准上甚至优于同规模直接 RL，说明推理模式可以“教会”而不必“重新发现”。

成本：官方 2025 年 9 月披露，R1 的 RL 增量训练成本仅约 **29.4 万美元**（V3 基座预训练约 \$5.6M）；作为对照，o1 的训练成本从未公开，外界普遍估计在数千万美元量级。R1 以开源权重 + 极低训练成本证明：推理能力不再是大算力公司的专属品——

这直接触发了 2025 年初的“DeepSeek 冲击波”（见第 11 章）。

蒸馏与 RL 的边界是 R1 论文留下的重要工程结论：把 R1 的推理样本蒸馏给 1.5B–7B 小模型，效果优于小模型自己跑 RL——说明推理“模式”可以低成本迁移；但小模型蒸馏版的天花板被老师锁死，要想“超越老师”，仍然需要更大的基座 + 完整的 RL 过程。这为业界画了一张实用路线图：应用型小模型走蒸馏（便宜、快），前沿能力探索走 RL（昂贵、但能产生新知识）。此外，思维链的可见性也成了产品决策：DeepSeek 公开完整思考链（利于研究、审计与信任），OpenAI 只展示摘要（防蒸馏、降低安全暴露面），Qwen3 干脆把“是否思考”做成用户可切的开关——同一技术，三种产品哲学。

7.3 过程奖励模型 (PRM)

类型	特点
ORM (结果奖励)	只看最终答案对不对
PRM (过程奖励)	对每一步推理打分

表 14: 奖励模型类型

ORM vs PRM 的本质差异：ORM 只对“最终答案”打分，模型可以“蒙对”（答案正确但推理错误），奖励信号是稀疏的；PRM 对每一步中间状态打分，奖励稠密、能定位错误发生的位置，代价是需要大量过程标注（如 PRM800K 数据集约 80 万条逐步标注）。推理时 PRM 通常与搜索算法联用：Beam Search / MCTS 展开多条推理路径，用 PRM 分数剪枝——这本质上把“单次生成”变成了“带评估的搜索”，是 Test-time Compute 的另一实现形态。2025 年后，随着 LLM-as-a-Judge 质量提升，自动化过程评估（让强模型为弱模型的推理逐步打分）成为降低标注成本的主流手段。

来自 R1 的反面证据：DeepSeek-R1 论文把 PRM 与 MCTS 均列为失败的尝试——显式 PRM 难以可靠判定中间步骤的正确性、天然易被 reward hacking，且每轮搜索迭代都需重训奖励模型；MCTS 则受制于指数级搜索空间与“如何把生成切成可搜索的步”这一未解难题。这解释了 2025 年主流路线为何收敛于“纯 RL + 规则奖励 + 自由长思考”：与其外挂搜索，不如让策略网络把搜索行为内化进参数。

2025 趋势：

- **Automated PRM**：用 LLM 自动生成分步评估
- **MCTS + PRM**：AlphaGo 思路用于数学推理
- **Test-time Compute**：增加推理时间换准确率

7.4 推理训练技术栈

数据构造 (CoT · 自我博弈 · 拒绝采样) → SFT → RL (PPO/GRPO)
→ 测试时策略 (ToT/MCTS)

7.5 推理的边界与局限

- **幻觉**：知识性 vs 指令性；缓解：RAG、Self-Consistency
- **长 CoT 陷阱**：过长的思考链引入噪声；“思维链不忠实”现象
- **组合推理极限**：多步推理错误率累积
- **2025 前沿**：推理 + 工具（搜索/计算器/代码执行）、Agentic 推理、世界模型

必须清醒认识的三点局限


1. **CoT 忠实性问题**：Turpin et al. (2023) 等研究证实，模型输出的“思考过程”不一定反映其真实的决策依据——模型可能“先知道答案，再编造理由”。因此不能把 *CoT* 当作可审计的解释，高可靠场景需要外部验证器（执行代码、对照知识库）。
2. **奖励 hacking 的推理版**：当奖励来自 LLM 评审或宽松判分时，模型会学会“表演推理”（冗长但空洞的思考链）而非真正推理——奖励信号的可验证性（代码单测、数学答案比对）是推理 RL 质量的上限。
3. **推理的边际收益递减**：Test-time Compute 的幂律在特定难度后会饱和，且成本线性增长；工程上需要“思考预算”机制（o3 的可配置预算、Qwen3 的 /think 与 /no_think 双模式）在成本与准确率之间做显式权衡。

8 多模态大模型

8.1 架构范式

视觉 token 的成本账值得单独一算：一张 1024×1024 图片经 patch 切分与动态分辨率适配后，通常产出数百至上千个视觉 token，相当于数千字文本——多模态请求的实际推理成本常是纯文本的 5–10 倍，且大头在预填充。因此第 6 章的推理优化在多模态场景从“可选项”变成“必需品”：视觉 token 压缩（平均池化/查询压缩）、图像前缀缓存、按需分辨率调度，本质都是在“看得清”与“算得起”之间找平衡。

三种融合范式值得区分：



视觉 token 成本：一张 1024^2 图 $\approx$ 数百至上千 token，是多模态请求成本的大头

图 11: 多模态大模型的标准架构：各模态先经专用编码器压缩为 token 序列，由投影层对齐进 LLM 词表空间后与文本统一处理——融合发生的位置（投影层 vs 第一层）区分了拼接式与原生式两大路线。

- 拼接式 (Late Fusion + Adapter)：** 模态编码器独立预训练，经投影层映射到 LLM 词表空间后拼接 (LLaVA、Qwen-VL、InternVL 均为这一路线)——工程上最成熟，视觉编码器可冻结，训练成本低；
- 早期融合 (Early Fusion)：** 不同模态从第一层起就在同一 Transformer 内交互 (Gemini 原生多模态路线)——跨模态推理上限更高，但训练成本高、需要海量配对数据；
- 统一自回归 / 扩散混合：** 生成侧用扩散模型 (图像/视频)、理解侧用 LLM (Sora、Veo、可灵的“理解 + 生成”双管线)。

对齐 (Projection) 是多模态模型的关键瓶颈：视觉 token 与文本 token 的语义粒度天然不对齐 (一个 14×14 patch 对应几十个语义维度)，投影层设计 (线性 vs MLP vs Q-Former/Perceiver Resampler) 直接决定细粒度能力 (OCR、图表、空间关系) 的上限。

8.2 视觉语言模型 (VLM)

VLM 的标准训练配方 (以 LLaVA 系、Qwen-VL 系为代表) 分两阶段：

- 对齐阶段 (Alignment)：** 冻结视觉编码器与 LLM，只训练投影层；数据用“图文对 + 图像描述”，目标是把视觉 token 拉进语言空间——这一阶段决定跨模态“对得准不准”；
- 指令微调阶段 (SFT)：** 解冻 LLM (或 LoRA)，用多任务数据 (VQA、OCR、图表理解、文档问答、视频时序) 联合训练——决定“用得对不对”。

2024–2025 年的两个关键改进：(1) **动态分辨率**——放弃固定 336×336 裁剪，按图像长宽比自适应切 patch (Qwen2-VL 的 Naive Dynamic Resolution)，直接带来 OCR 与文

模型	架构	特点
LLaVA 系列	CLIP ViT + 线性投影 + LLaMA	开源标杆
InternVL 系列	ViT + MLP 投影 + LLM	开源多模态第一梯队
Qwen2.5-VL	原生动态分辨率 + 视频	OCR/文档理解标杆
GPT-4o	原生多模态（非拼接）	实时语音交互
Gemini 2.5/3	原生多模态 + Deep Think	文本 + 图 + 音 + 视频统 一

表 15: 代表性 VLM

档理解能力的代际提升；(2) **视觉 CoT**——在推理模型时代（第 7 章），VLM 同样引入长思考（先描述再推理、先规划搜索区域再作答），Gemini 与 Qwen 的 thinking 视觉模型即为代表。

8.3 音频/语音

- **ASR**：Whisper（约 100 种语言、68 万小时训练数据）、SenseVoice
- **TTS**：VALL-E、CosyVoice、F5-TTS、NaturalSpeech 3
- **实时语音对话**：GPT-4o Live、Gemini Live（2025 主流）
- **2025 趋势**：全双工语音、情感/语调可控 TTS、低延迟流式推理

技术要点：现代 TTS 的主流路线是声码 *token* 化——用 EnCodec 类神经编解码器把语音压成离散 token 序列，TTS 就退化为“文本 token → 语音 token”的自回归/流匹配生成问题，从而复用 LLM 工具链。Whisper 则证明 68 万小时多语言数据 + 强数据质量足以训出通用 ASR。实时语音对话（GPT-4o Live、Gemini Live、国内豆包/通义电话级产品）的端到端延迟预算通常要求 <500ms，工程上依赖：流式 VAD（端点检测）+ 流式 ASR + 小模型快答 + 流式 TTS 首包优化；更激进的方向是“语音-文本同一模型”（end-to-end speech LLM），省掉 ASR/TTS 级联的信息损失，但成本与可控性仍是瓶颈。

8.4 视频理解与生成

- **理解**：Qwen2-VL（视频）、Gemini（原生视频）
- **生成**（2025 竞争格局）：
 - Sora 2（OpenAI, 2025-09）：物理一致性大幅提升，同步推出独立 App 走短视频社区路线

- Veo 3 / 3.1 (Google, 2025-05/10): 首个音画同步 (原生生成对白与音效) 的视频模型
 - Kling/可灵 2.x (快手): 国产代表, 首帧/多参考图控制成熟
 - Seedance 1.0 (字节, 2025-06): 极致推理性价比; Runway Gen-4: 商业 workflow
 - 开源阵营: 通义万相 Wan2.2、HunyuanVideo、LTX-Video
- **技术路线**: Diffusion Transformer (DiT)、3D 卷积 + 时间注意力、潜空间视频扩散

视频生成的架构共识 (Sora、Veo、可灵、Runway 殊途同归): (1)**3D 时空 VAE**——把视频压进潜空间 (时间维压缩 $4\times$ 左右、空间维压缩 $8-16\times$), 扩散/流匹配在潜空间进行, 把计算量降低一到两个数量级; (2)**DiT**——用 Transformer 替代 U-Net 作为生成骨干, 天然支持任意分辨率与时长的 scaling; (3) **条件注入**——文本经交叉注意力或联合序列注入。2025–2026 的竞争焦点已从“能不能生成”转向物理一致性 (遮挡、流体、碰撞)、长时一致性 (角色/场景不漂移) 与音画同步 (Veo 3、可灵 2.x 的原生音频), 以及成本——单条 5 秒视频 720p 的推理成本已降至数美分级别。此外, Google Genie 3 (2025 年 8 月) 代表另一条路线——可交互世界模型: 不生成固定视频, 而是根据文本实时生成可自由探索的 3D 一致世界; 它与 LeCun 的世界模型主张共同指向“视频生成之后的下一个范式” (见第 10、12 章)。

8.5 多模态训练与推理

训练: 视觉-语言对齐与指令微调的两阶段配方 (见上节) 解决“看得懂”, 而 2025 年起多模态后训练的重心转向“想得对、做得准”——(1) **多模态 RLHF/RL**: 以人类偏好对齐图像质量与安全性, 并用可验证奖励 (定位框 IoU、OCR 精度) 做 GRPO 类强化, Qwen-VL 系率先报告视觉定位能力的显著提升; (2) **视觉 CoT**: 先描述图像、先框选感兴趣区域再推理——推理模型范式 (第 7 章) 自然延伸到视觉域, OpenAI o3 的“以图思考” (thinking with images) 是代表, 图像本身成为推理过程中可操作的中间变量; (3) **Agent 化**: 屏幕截图理解 → 规划操作 → 执行反馈, GUI Agent 从 demo 走向产品——OpenAI Operator (2025 年 1 月, 底层 CUA 模型)、Claude Computer Use、字节开源的 UI-TARS 与智谱 AutoGLM, 以及 2025 年 3 月出圈的通用 Agent Manus。

推理: 多模态请求 (图文交错输入、视频帧采样、长上下文视觉 token) 使 KV Cache 与预填充成本远高于纯文本, 工程上依赖**视觉 token 压缩** (平均池化/查询压缩降低每图 token 数)、**前缀缓存** (共享图像的 KV 复用) 与**动态分辨率**调度; vLLM/SGLang 均已原生支持图文交错输入与视觉前缀缓存, 是 2025 年多模态服务化的标配。

9 安全、对齐与治理

9.1 对齐技术栈

对齐 (Alignment) 的目标是：让模型的输出分布与人类意图、价值观保持一致，而非仅仅“预测下一个 token”。工业实践中没有银弹，而是**多层防御纵深** (defense in depth)——每一层都假设其他层可能失效：

1. **Constitutional AI** (Anthropic)：用“宪法”原则指导自我批评 + RLAIIF
2. **System Prompt 工程**：安全指令 + 行为约束 + 角色设定
3. **输出过滤**：分类器检测有害内容、关键词过滤、置信度阈值
4. **红队测试 (Red Teaming)**：自动化攻击 (越狱、提示注入) + 人工红队
5. **评估与审计**：安全基准 (SafetyBench、HarmBench、AdvBench)、透明度报告、第三方审计

其中训练时对齐 (1) 是根基，部署时防御 (2-3) 是护栏，运营时对抗 (4-5) 是持续更新机制。值得强调的是：任何单点防御都可被绕过 (2024-2025 年的多项研究已系统性攻破单一 jailbreak 过滤器)，只有纵深 + 持续红队才能维持安全水位——这与网络安全领域“没有绝对安全”的共识一致。

2025-2026 年的四个新焦点：(1)**Agent 与提示注入**——模型能“执行动作”之后，间接提示注入从“内容风险”升级为“执行风险” (被投毒的网页/文档/工具描述可诱导 Agent 泄露数据或执行恶意操作)，OWASP LLM Top 10 与多国安全机构均将其列为一号威胁，防御转向权限最小化、人机确认 (human-in-the-loop)、沙箱执行与动作审计；(2)**CoT 忠实度**——推理模型的可见思考链未必反映真实决策依据，把“监控思考链”本身作为安全机制存在系统性风险 (Anthropic 2025 年委托的独立研究对此发出明确警告)；(3) **模型混淆与来源**——AI 生成内容的水印/显隐式标识 (中国《标识办法》、C2PA 内容凭证、Google SynthID 类水印) 从技术选项变成合规义务；(4) **攻防自动化**——LLM 驱动的自动化越狱与自动化红队同时成熟，安全水位从“发布时达标”转向“持续运营指标”。




图 12: 多层防御纵深 (defense in depth)：训练时对齐是根基，输入/输出防御是护栏，红队是持续校准机制——任何单层都可被绕过，安全水位取决于整条链与回流的闭环。

9.2 关键安全挑战

威胁	防御手段
越狱 (Jailbreak)	输入过滤、多轮上下文监控、对抗训练
幻觉与虚假信息	RAG、引用来源、置信度表达
偏见与公平性	去偏数据、公平性约束、多视角评估
隐私泄露	差分隐私、数据脱敏、本地化部署
提示注入	输入隔离、权限最小化、沙箱执行
AI 武器化	访问控制、速率限制、内容审计

表 16: 安全威胁与防御

2025–2026 新挑战：

- **AI 生成内容识别**：深度伪造与信任链危机——显式标识、隐式水印 (SynthID 类) 与内容凭证 (C2PA) 三条路线并行，中国《标识办法》已将显式 + 隐式标识定为强制义务；
- **模型窃取**：API 逆向蒸馏与模型提取攻击持续演化；蒸馏检测（输出分布指纹）技术尚不成熟，成为开源–闭源之争中的焦点议题；
- **供应链攻击**：恶意插件、MCP 工具描述投毒、模型仓库污染——权重与工具链本身成为新的攻击面；
- **行业自律升级**：2025 年 OpenAI、Anthropic、Google 等联合发布 AI 网络安全防御公开信 (100+ 公司签署)；前沿实验室普遍建立“准备度框架” (Preparedness Framework)，按能力风险等级设定部署门槛与红队强度。

9.3 治理与监管

AI 治理正在从“原则宣言”走向“可执行法规”。主要司法辖区的框架对比：

- **EU AI Act** (2024 年 8 月生效, 2025–2027 分阶段实施)：风险分级监管——不可接受风险（如社会评分）禁止、高风险（招聘、医疗）严格合规义务（数据治理、日志、人工监督）、有限风险（透明度义务）、最小风险自由。全球首个综合性 AI 法，具有“布鲁塞尔效应”——2025 年 8 月起 GPAI（通用模型）义务生效，2026 年 8 月全面适用。
- **美国**：联邦层面以 NIST AI 风险管理框架 (AI RMF 1.0/2.0) + 行政令为主，2025 年政策转向“竞争力优先”，监管权下放至州（如加州 SB 1047 的立法博弈）；各机构 (FDA、SEC、FTC) 在各自领域并行监管。

- **中国**：《生成式人工智能服务管理暂行办法》（2023 年 8 月生效）+ 大模型备案制度（网信办“生成式 AI 服务”备案与深度合成算法备案双轨）+ 《人工智能安全治理框架》（1.0/2.0 版）；特色是发展与安全并重的路径——备案制降低合规不确定性，同时推动行业安全基线（内容安全、训练数据合法性、个人信息保护）。2025 年起，面向公众的生成式服务需通过备案并履行安全评估义务；《人工智能法》已列入立法规划、处于草案研究阶段。
- **国际**：Bletchley AI 安全峰会（2023）→ 首尔峰会（2024）→ 2025 年 AI 安全治理进程延续；联合国 AI 治理对话、ISO/IEC 42001（AI 管理体系）等标准加速落地；OECD AI 原则成为多数国家立法的参照系；2025 年 8 月联合国大会决议设立独立国际科学小组与治理全球对话双机制，全球治理框架初具雏形。

给从业者的合规要点（中国语境）

面向公众提供生成式 AI 服务需完成：**算法备案**（深度合成/生成式）+ **安全评估** + **内容标识**（《人工智能生成合成内容标识办法》2025 年 9 月 1 日起施行，要求显式 + 隐式标识）；训练数据需合法来源、不得侵犯知识产权与个人信息；跨境数据传输遵守《数据安全法》《个人信息保护法》。这三条是 2025–2026 年国内 AI 产品上线的硬性门槛。

10 可扩展性定律与未来方向

10.1 Scaling Laws 演进

10.1.1 Kaplan Scaling Laws (2020)

$$L \propto N^{-0.076} \cdot D^{-0.095} \cdot B^{-0.050}$$

N = 参数量, D = 数据量, B = 计算量。结论：等比扩展。

幂律的含义： $L \propto N^{-0.076}$ 意味着参数量每翻一倍，损失仅降低约 $1 - 2^{-0.076} \approx 5\%$ ——扩展是“有效但缓慢”的。幂律的工程价值在于可外推性：用 1B–7B 小规模模型测得的曲线，可以相当可靠地预测 100B 级别的行为，这使“花小钱验证大钱决策”成为可能，也是后来所有 Scaling Law 研究的起点。Kaplan 报告的指数 D (0.095) > N (0.076)，暗示“数据比参数更值钱”——Chinchilla 用严谨实验证实并放大了这一结论。

10.1.2 Chinchilla Scaling Laws (2022)

DeepMind 用更严格的控制变量（固定算力预算，扫描不同 N/D 配比）修正了 Kaplan 的结论：**数据量应与参数量等比扩展，最优配比约为每 1B 参数训练 20B token**（即 $D \approx 20N$ ）。

例如：70B 模型 $\rightarrow \sim 1.4\text{T}$ token。Chinchilla 70B 用 1.4T token 训练，效果优于 GPT-3 175B (300B token) ——用 $\frac{1}{2.5}$ 的参数量、 $\frac{1}{5}$ 的算力达到更好的效果，核心贡献是指出了 GPT-3 被严重“欠训练于数据”。

但 Chinchilla 最优是针对训练成本最小化的最优。若把推理成本计入生命周期总账（模型要服务数年），结论会反转：训练更多 token、服务更小模型反而更划算。这正是 Llama 3 的选择：8B 模型训练 15T token（远超 $20N = 160\text{B}$ 的 Chinchilla 最优），405B 旗舰同样在约 15.6T token 上训练——业界称之为 *inference-aware scaling*。2025–2026 年的共识是：**Chinchilla 定律给出的是“训练侧”参考线，而产品经济学把最优推向“更少参数 + 更多数据 + 更多推理算力”的三角。**

10.1.3 超越 Chinchilla

- **Llama 3**：8B/70B/405B 全系 15T+ token——为多年推理服务而“过量训练”；
- **Qwen3**：36T token、119 种语言（2025 年开源阵营最大规模预训练），显著调高多语言与 Agent 数据权重；
- **DeepSeek-V3**：671B MoE 仅激活 37B、14.8T token——MoE 让“每 FLOP 换多少有效知识”成为新的比较基准；
- **数据质量路线**：Phi 系列证明“教科书级合成数据 + 严格过滤”可用 14B 逼近更大稠密模型的推理能力；合成数据闭环（模型生成 $\rightarrow$ 验证器过滤 $\rightarrow$ 回炉再训练）成为绕开数据墙的主力工程；
- **超参迁移** (μP)：小模型调出的最优超参可按解析规则映射到任意规模，降低“烧大钱试错”的风险。

综合判断：Scaling Law 的“第四轴”——推理时算力（第 7 章）已与参数、数据并列；2025–2026 年的共识公式是“**更少激活参数 + 更多高质量（含合成）数据 + 更长思考时间**”。

两个方法论警告：其一，“涌现能力”有相当部分是度量伪影——不连续指标（答对/答错）在连续的能力增长上自然产生跳变（Schaeffer et al., 2023），换用连续指标后“涌现”趋于平滑；其二，基准污染（benchmark contamination）——测试题经互联网泄漏进训练语料使分数虚高，2025 年后头部团队转向“私有题库 + 动态评测 + 人工复核”三件套。读榜单的正确姿势：同源对比、关注置信区间、警惕考古式刷榜；跨代比较时优先看 Agentic 与长周期任务（更难污染、更贴近真实价值）。




图 13: Scaling Law 的示意曲线（对数-对数坐标下近似直线）：在同等算力预算下，“数据等比”路线（Chinchilla）优于“参数优先”路线；数据质量与合成数据可将整条曲线进一步下压。

10.2 数据墙与计算墙

数据墙（Data Wall）

高质量公开人类文本可能于 2026–2032 年间耗尽（Epoch AI 估计）。解决方向：合成数据、多模态数据、交互数据、数据飞轮（模型生成 → 人类筛选 → 再训练）。

计算墙（Compute Wall）

单次训练 100B+ 模型成本 \$30M–\$100M+，能源消耗巨大。效率方向：MoE 稀疏激活、FP8/INT8 训练、MLA/线性注意力架构效率、高效优化器。

算力的地缘维度（中国语境）：2022 年起的高端 GPU 出口管制使 H100/B200 对华禁售、H800/H20 供应持续受限，中国训练栈事实上走出三条路线——其一，国产算力替代（华为 Ascend 910B/C 系列等，CANN 软件生态与 CUDA 的差距逐年缩小，MindIE/vLLM-Ascend 等推理适配层快速补位）；其二，以效率换算力（MoE、MLA、FP8、MTP 的激进组合，DeepSeek-V3 用 2048 块 H800 训出 671B 模型即是范本）；其三，算力调度优化（东数西算、算力租赁市场）。理解这个背景才能理解中国阵营的技术偏好：大量“效率创新”是被约束逼出来的，而约束反而造就了可输出的方法论——R1 的低成本 RL、Qwen3 的高性价比 MoE 都是例证。

10.3 能力收敛假说（CCH）：能力由访问结构定价

Scaling Laws 刻画的是训练侧的能力增长；而“规模能否自动换来智能”这一问题，在 2024–2026 年出现了理论转折。柏拉图表征假说（Platonic Representation Hypothesis, PRH；Huh et al., 2024）主张：随规模与数据多样性增长，异构网络的内部表征收敛到

共享的“现实统计模型”——在这一图景中，表征收敛是规模免费赠予的。然而 2026 年的实证工作揭示了 PRH 的“裂缝”：不同模型可以在表征空间中高度对齐，却在推理与决策行为上显著分歧（Usama 与 Chang, 2026）。

Chen et al. (2026, arXiv:2607.14144) 据此提出**能力收敛假说** (Capability Convergence Hypothesis, CCH)，作为 PRH 的“续篇与边界”：**在固定 per-token 推理预算下，表征收敛不蕴含能力收敛**。能力并不收敛到一个点，而是收敛到一个类——访问完备混合体 (access-complete hybrid)：凡同时持有两类信息通道的架构都落入该类。论文的核心论断可以压缩成一句话：

CCH 核心论断

表征收敛由规模免费赠予；能力收敛必须通过访问结构购买。智能（能力）不是规模的副产品，而是在固定每 token 预算下、由架构的**访问结构** (access structure，即模型能以何种通道访问历史信息) 所约束的产物。

10.3.1 能力的操作化定义：历史-查询通道

先厘清两个常被混用的词。**表征** (representation) 回答“看到什么”——模型对数据的内部地图；**能力** (capability) 回答“能做到什么”——在有限的每 token 预算内检索具体事实、执行复合逻辑。CCH 把后者形式化为**历史-查询通道** (history-to-query channel)：模型读入一段可以无限长的文本流，真正能用于回答查询的只有**可访问状态** Σ ——一个容量为 B 比特的瓶颈。无论模型总参数多大、表征多“柏拉图”，超出 Σ 容量的历史信息都对查询不可见。换言之，能力不是模型“知道什么”，而是它在预算内“能访问什么、能对访问到的东西计算什么”——这可以看作对“智能”的一种操作化定义：智能被归结为预算约束下的可回答查询类，而非参数规模或表征质量本身。

10.3.2 访问结构：双通道完备类

CCH 断言，固定预算下的能力收敛到“访问完备混合体”这一类：任何同时持有以下两种通道的架构都是完备的；缺任何一条通道，都有某类查询被证明无法完成——

- **压缩态通道** (compressive $O(1)$ -state channel)：把整段历史压缩成常数大小的运行状态 (SSM/RNN 式递归态、有限维汇总向量)，天然擅长状态跟踪与聚合类查询，但保留不下任意久远事件的逐字细节；
- **逐字索引通道** (scalable verbatim-index channel)：可随历史增长的逐字索引（注意力的 KV Cache、外置检索库），擅长精确回查原文，但单独持有它并不解决串行复合与状态聚合。

10.3.3 见证任务与三堵墙

CCH 把上述论断锚定在一个**见证任务**上：**无限流中的牛顿苹果问题**——在无限延长的 token 流中，某个时刻一个“苹果落地”式的具体事件被写入历史；模型既要在任意久之后仍能**逐字回查**该事件的内容与位置，又要在整条流上维持**运行状态**（计数、聚合、状态跟踪）。“召回 + 状态跟踪”这一复合任务原语的识别来自 Rawat et al. (2026) 的实证。在固定预算且无链式思考（no-CoT）的条件下，任何单一通道架构都会撞上至少一堵**资源之墙**：

墙	挡住的架构	理论依据
香农墙	一切 $o(N_b)$ 状态架构：逐字保留长历史不可能	数据处理不等式 + Fano（无条件）
视界墙	一切固定窗口架构：窗外历史不可达	窗口外的信息物理上无法访问
电路墙	固定深度纯注意力栈：串行复合受限	$\log\text{-精度 Transformer} \subseteq \text{TC}^0$ （条件于 $\text{TC}^0 \neq \text{NC}^1$ ）

表 17: CCH 的三堵资源之墙（Chen et al., 2026）：香农墙来自信息论、无条件成立；电路墙是复杂性条件结论。

在显式的**可分离性假设**下，双通道混合体“按每堵墙的价格付费”（分别支付状态容量、窗口覆盖、组合深度的工程代价）即可逐一穿越三墙——因此**能力在复合下严格超可加**（strictly super-additive）：两条各有短板的通道组合后，能完成任何单通道都无法完成的查询。这是“ $1 + 1 > 2$ ”的架构定理版本，也为第 4 章“RAG 事实层 + SFT 行为层正交可叠加”的生产经验提供了理论注脚。

预注册实验：这篇论文最值得业界学习的是方法论纪律——**在数据冻结前冻结判据**。三项预测如期命中：**剪刀差**被精确测得（64 个标量的压缩态在精确回查任务上错误率 0.994，仅增加一层全局注意力后骤降至 0.000）；状态跟踪能力的分岔正好落在预注册边界上；合取见证任务显示出不可约的双通道解。另有一项预测失败且方向反转，作者如实报告。论文同样明确区分已证明的与仍是猜想的：访问完备性原理基于信息论下界与预注册实验，而“领域级能力收敛趋势”只是经济学动机的猜想——这种自我设限的写法，与 10.1 节的评测方法论（度量伪影、基准污染）互为呼应。

10.3.4 用 CCH 回照本报告：访问结构的工程版图

CCH 提供了一个把本报告多个章节串起来的统一视角——过去十年的许多“架构创新”，本质上都是在为这两条通道支付账单或扩展账本：

这张表也解释了 2025–2026 年架构竞争的真实格局：**纯 SSM、纯注意力、纯检索都不是终点，“混合 + 外置”才是通往访问完备的工程路线**——Jamba 类混合架构、长上下文与 RAG 并用的生产组合、把推理深度转移到测试时的推理模型（第 7 章），都




图 14: CCH 的双通道访问结构与三堵墙（示意）：单一通道必被至少一堵墙挡住；同时持有压缩态与逐字索引双通道的混合体按每堵墙的价格（状态容量、窗口覆盖、组合深度）逐一穿越，能力在复合下严格超可加（Chen et al., 2026, arXiv:2607.14144）。

CCH 概念	工程对应	本报告章节
$O(1)$ 压缩态通道	线性注意力 / SSM (Mamba); RNN 遗产	第 2、5 章
逐字索引通道	KV Cache 与长上下文管理	第 6 章
外置逐字索引	RAG (“事实层”检索增强)	第 4 章
视界墙的工程价格	滑动窗口、YaRN 位置外推、长文本课程	第 5、6 章
电路墙的工程价格	链式思考：以测试时计算换组合深度	第 7 章
访问完备混合体	SSM × 注意力混合架构；“RAG + SFT”组合	第 4、5 章
能力的超可加性	事实靠检索、行为靠微调，两者正交可叠加	第 4 章

表 18: 用 CCH 对照本报告：访问结构概念的工程对应

是在同一本“访问结构账”上的不同记账方式。最后需要强调边界：CCH 的实验仍是小规模预注册测试，“领域级收敛”是猜想而非定理，且其结论限于无 CoT 的固定预算情形——但“能力由访问结构定价”这一视角，对理解第 11 章的算力-资本-生态格局与第 12 章的趋势判断，已经足够有力。

10.4 未来方向 (2025–2030)

其中世界模型与具身智能值得单独展开。世界模型路线（LeCun 的 JEPA 主张、Genie 3 的可交互世界生成、视频生成模型中被广泛讨论的“隐式物理解”）的核心命题是：语言是对世界的有损压缩，先建立物理直觉再谈智能——这与“纯语言训练触顶”的判断互为印证。具身智能则把 LLM 当“大脑”（任务规划与语义理解），把 VLA（视觉-语言-动作）小模型当“小脑”（低层控制），2025 年中国具身智能赛道 73 笔、257 亿元的融资热度与 2026 年“世界模型元年”的说法互为表里——两条线最终会在“能动手的智能体”上汇合。

方向	描述
推理为王	从“更大模型”转向“更聪明推理” (Test-time Compute)
Agent 化	LLM 从“回答者”变为“行动者” (工具调用、多步规划)
多模态统一	文本 + 图像 + 音频 + 视频 + 3D 统一在一个模型
效率革命	MoE + 量化 + 推测解码, 100B+ 可在消费级硬件运行
访问结构工程	混合架构与外置记忆: 按 CCH 补齐能力通道 (10.3 节)
AI for Science	蛋白质设计、材料发现、数学定理证明
端侧 AI	手机/PC 上的 1B–10B 模型成为标配
Agent 协议 (MCP)	Agent 连接工具/数据的事实标准 (2026)
具身智能	LLM + 机器人, 操作物理世界
世界模型	AI 内部模拟物理/社会环境

表 19: 2025–2030 关键趋势

11 2025–2026 行业前沿动态

本章汇总 2025 年至 2026 年上半年的行业关键进展。**阅读提示：**本章内容主要来自厂商公告与行业公开报道，个别 2026 年事件（如 NVIDIA 收购 Hugging Face、Gemini 3.7、Google I/O 2026 主题等）的量化细节（金额、具体型号参数）以最终官方披露为准；引用这些数据用于正式文档前，建议回溯一手来源核实。

本章三条主线：(1) **推理与 Agent 成为产品主形态**——o1→o3、R1、Gemini thinking 系列把“思考预算”做成产品开关，Operator/Computer Use 把“执行动作”做成标准能力；(2) **开源与闭源差距收敛**——Qwen3、Llama 4、DeepSeek 系列在核心基准上逼近同期闭源旗舰，开源阵营首次具备“生产级推理模型”选项；(3) **算力与生态整合加速**——NVIDIA 的纵向整合（芯片 → 框架 → 生态）、云厂商的自研芯片（TPU v6、Trainium 2/3）与数据中心扩张构成基础设施主战场。

行业关键事件：

- NVIDIA 以近 \$130 亿收购 Hugging Face，算力 + 开源生态深度绑定
- OpenAI、Anthropic、Google 联合发布 AI 网络安全防御公开信（100+ 公司签署）
- Suno（AI 音乐生成）面临多位音乐人的风格模仿诉讼
- Adobe 工具深度集成 Slack，AI 辅助设计 workflow 成熟
- 大型数据中心环保争议（天然气发电、联邦法律违规指控）
- Google I/O 2026 宣布 “Agentic Gemini 时代”
- ChatGPT 推出临时聊天、个性化、插件等持续迭代

公司/项目	最新进展	亮点
OpenAI	o3/o4-mini (2025-04)、GPT-5 (08)、GPT-5.2 (12)、Sora 2、Operator	推理 + Agent + 多模态统一
Google	Gemini 2.5 → Gemini 3 Pro (2025-11, LMArena 1501)、Veo 3/3.1、Genie 3	原生多模态 + 世界模型
Anthropic	Claude 4 (05) → Opus 4.5 (11, SWE-bench 80.9%)、Computer Use	编程与 Agent 执行标杆
Meta	Llama 4 (2025-04, Scout/Maverick)	大规模 MoE 开源 (评测有争议)
xAI	Grok 3 (02) → Grok 4 (07, 多智能体)	10 万卡 Colossus 算力
DeepSeek	R1 (01)、V3.1 (08)	MLA、纯 RL 推理、RL 成本 29.4 万美元
阿里	Qwen3 (04)、Qwen3-Coder (07)	36T token 预训练、开源矩阵最全
月之暗面	Kimi K2 (07)	1T 级 MoE 全量开源，开源榜第一
智谱	GLM-4.5 (07)、2026-01 港股上市	大模型第一股
NVIDIA	B200/GB200、约 \$12.9B 收购 Hugging Face (2026-08)	算力 + 生态纵向整合

表 20: 2025–2026 主要玩家动态

11.1 2025 年时间线：从 DeepSeek 冲击波到多极格局

- 1 月：DeepSeek-R1 发布（对标 o1），数日内登顶中美应用商店，引发 NVIDIA 单日市值蒸发约 5890 亿美元（跌幅约 17%）——DeepSeek 冲击波成为全年行业叙事的分水岭；OpenAI 发布 Operator（CUA 模型），打响 Agent 元年第一枪；
- 2 月：xAI Grok 3 发布（10 万张 H100 的 Colossus 集群训练）；EU AI Act 禁止性条款开始适用；
- 3 月：通用 Agent Manus 出圈（GAIA 基准超越 OpenAI DeepResearch）；GPT-4o 原生图像生成上线，一周内 1.3 亿用户生成超 7 亿张图；
- 4 月：o3 / o4-mini 发布（推理模型首次全工具链调用）；Llama 4（Scout/Maverick, MoE）发布但评测口径陷入争议；Qwen3 发布（36T token、119 种语言、混合思考）；
- 5 月：Claude 4 系列（Opus 4 / Sonnet 4）确立编程标杆；Google I/O 发布 Veo 3（首个音画同步视频生成）；

- **6–7 月**：o3-pro；**Kimi K2** 万亿参数全量开源（LMArena 开源第一）；Qwen3-Coder（Agentic Coding 开源 SOTA）；GLM-4.5（355B MoE）开源；Grok 4（多智能体 Heavy）；
- **8 月**：**GPT-5** 发布（快慢思考统一路由，幻觉率较 o3 大幅下降）；OpenAI 时隔多年重回开源（GPT-oss-120B/20B）；DeepSeek-V3.1（混合思考 + 强代码）；Google Genie 3 世界模型；
- **9 月**：Sora 2 + 独立 App（被称作视频界的 GPT-3.5 时刻）；中国《人工智能生成合成内容标识办法》施行；DeepSeek 经 Nature 封面论文披露 R1 训练成本仅 29.4 万美元；
- **10–12 月**：Claude Opus 4.5（SWE-bench 80.9%，首个破 80）；**Gemini 3 Pro**（LMArena 首破 1500 Elo，GPQA 91.9%）；Veo 3.1；GPT-5.1 / 5.2；据报道 Manus 被 Meta 收购；
- **2026 年 1 月**：智谱 AI 港股上市（全球大模型第一股）、MiniMax 上市首日涨 109%；LeCun 离开 Meta 创立 AMI Labs 押注世界模型；三大实验室同步进军医疗 AI。

11.2 中国力量：从追赶到并跑

开源阵营的主导权已明显东移：2025 年全球开源模型的下载量与衍生生态中，中国模型占据多数份额；在生产级推理与 Agent 能力上，开源首次与闭源并肩。代表阵营：

- **DeepSeek**：R1（RL 成本 29.4 万美元）→ V3.1（混合思考、强代码）；以 MLA / MTP / FP8 / 无辅助损失 MoE 的架构-系统协同路线持续压低训练与推理成本，是全年行业成本曲线的锚点；
- **阿里 Qwen**：Qwen3 全系开源（0.6B–235B，Apache 2.0），36T token 预训练、119 种语言，衍生模型生态为全球最大；Qwen3-Coder 补齐 Agent 编程短板；
- **月之暗面 Kimi**：K2 以 1T 级 MoE 全量开源并登顶开源榜，验证 Agentic 数据工程 + 大 MoE 路线；
- **智谱 GLM**：GLM-4.5（355B MoE）开源，2026 年 1 月率先登陆港交所成为全球大模型第一股；
- **字节跳动**：豆包系产品用户量居国内首位，Seedream 4.0（图像生成/编辑一体化）与 Seedance 1.0（视频生成）在多模态侧形成竞争力；
- **MiniMax**：M1（长上下文混合架构）与海螺视频，2026 年 1 月上市首日市值破千亿港元。

产业与资本面：2025 年 1–10 月中国 AI 领域超亿元融资 139 笔、总额超 600 亿元人民币，其中具身智能 73 笔、257 亿元；监管侧备案制 + 内容标识双轨落地（见第 9 章），发展与规范并重。

11.3 算力、资本与开源生态

算力：NVIDIA Blackwell (B200/GB200) 进入规模部署，2026 年 8 月官宣以约 129 亿美元收购 Hugging Face（含约 119 亿美元现金，进入 HSR 反垄断审查）——芯片 + 框架 + 模型生态的纵向整合引发开源社区对中立性的担忧；云厂商自研芯片（TPU、Trainium、MTIA）继续分流；吉瓦级数据中心的能源与环评（燃气发电、核电 PPA）成为新的瓶颈议题。**资本：**OpenAI 完成 400 亿美元融资（估值 3000 亿美元）、2026 年营收目标 300 亿美元；Anthropic F 轮 130 亿美元（估值 1830 亿美元）；行业在 AI 泡沫争议中进入以真实 ROI 论成败的价值证明之年。**开源生态：**MCP 协议捐赠开源基金会、成为 Agent 连接工具的事实标准；OpenAI 重回开源（GPT-oss）、Llama 4 争议动摇 Meta 的开源信誉、Qwen/Kimi/GLM 补位——开源重心从单点旗舰转向全栈生态（权重 + 推理引擎 + Agent 框架 + 协议）。

12 总结与展望

12.1 技术栈全景



图 15 从系统视角把六层串成一个闭环：数据经训练变成模型，模型经部署触达应用，应用产生交互数据与安全信号回流——大模型竞争的本质是飞轮转速之争。

最后给一个三遍读法的建议：第一遍只读每章的 keybox/infobox 与全部图示（约 45 分钟），建立全景地图；第二遍带着手头的具体问题精读对应章节（本报告刻意让每章可独立成篇）；第三遍顺着“关键论文与延伸阅读”读原始文献——技术报告的价值在于把问题“问到点子上”，而答案永远在原始来源里持续更新。




图 15: 大模型技术栈的运行闭环：每一轮迭代都在为下一轮积累数据与评估资产。飞轮各环节分别对应第 4 章（训练）、第 5–6 章（模型与部署）、第 8 章（应用形态）与第 9 章（评测与安全）。

12.2 核心趋势

趋势判断的方法论：以上趋势并非并列的“新方向”，而是沿算力分配这条主线展开——训练算力（参数/数据扩展）边际收益递减后，算力向推理侧（test-time compute）、向架构效率（MoE/MLA/SSM）、向端侧（量化/小模型）重新配置；“安全内生”与“Agent 化”则是这一重新配置在治理与应用层的投影。理解这一主线，就能从趋势列表中推演出尚未出现的产品形态。

1. **推理为王：**Test-time Compute 成为新扩展维度（思考预算已成产品开关）
2. **Agent 化：**LLM 从“回答者”变为“行动者”，MCP 等协议成为互操作底座
3. **多模态统一：**单一模型处理文本、图像、音频与视频（理解 + 生成）
4. **效率革命：**MoE + 量化 + 推测解码，100B+ 模型可在消费级硬件运行
5. **访问结构经济学：**能力由“压缩态 + 逐字索引”双通道的完备性定价，混合架构与外置记忆成为能力竞争的新前线（见 10.3 节）
6. **AI for Science：**从工具到发现者（蛋白质、材料、数学）
7. **安全内生：**从“事后过滤”到“训练时对齐 + 运营时审计”
8. **开源东移：**Qwen、DeepSeek、Kimi、GLM 与 Llama 并立，开源首次覆盖生产级推理与 Agent 能力
9. **端侧 AI：**隐私优先的本地推理（1B–10B 模型进手机/PC）
10. **世界模型：**从语言走向物理（Genie 3、AMI Labs），为具身智能铺路

2026 年值得盯住的三个变量：一是世界模型能否从演示走向可用（Genie 3 类可交互世界、AMI Labs 路线）；二是上市潮能否经受盈利检验（头部的 IPO 预期与港交所已上市公司的商业化数据）；三是监管全面生效（EU AI Act 2026 年 8 月全面适用、中国标识义务常态化）对产品形态的实际约束。

12.3 给学习者的建议

- **基础**：线性代数、概率论、优化理论、Python
- **框架**：PyTorch 精通 → JAX（研究前沿）
- **实践**（由浅入深）：
 - 从 0 复现 Transformer（含 KV Cache 与 FlashAttention 思想）
 - 训练 1B 小模型（预训练 → SFT），走完一条完整数据管线
 - 部署 vLLM/SGLang 推理服务，动手实践量化与推测解码
 - 复现 DPO 与 R1 风格 GRPO（规则奖励 + 可验证任务）
 - 用 LoRA/QLoRA 做领域适配，并构建一个 MCP 工具调用 Agent
- **前沿追踪**：arXiv (cs.LG, cs.CL)、HuggingFace、顶会 (NeurIPS/ICML/ICLR/ACL)；中文社区：机器之心、量子位、智源社区、ModelScope 与 GitHub 中文区
- **工具链**：Transformers + DeepSpeed/Megatron-LM + TRL/LLaMA-Factory + vLLM/SGLang + W&B

最后的话

大模型技术栈的特点是**半衰期短**：本报告中的具体模型与数字（参数、成本、基准）会以季度为单位被刷新，但架构原理（注意力、稀疏化、对齐）、系统原则（并行切分、显存账本、算术强度）与方法论（Scaling Law、控制变量、防御纵深）会以年为单位稳定。把时间投资在后两者上，是应对技术快速迭代的最优策略。

A 关键技术速查表

术语	英文	一句话解释
注意力	Attention	让模型动态决定“看哪里”的机制
多头注意力	Multi-Head Attention	多组并行注意力捕捉不同关系
因果掩码	Causal Mask	确保只能看到前文，实现自回归
位置编码	Positional Encoding	注入 token 位置信息
RoPE	Rotary Position Embedding	旋转矩阵编码位置，支持外推
MoE	Mixture of Experts	稀疏激活专家网络
GQA	Grouped Query Attention	分组 KV 头，减少 Cache
MLA	Multi-head Latent Attention	联合压缩 KV，极致省显存
KV Cache	Key-Value Cache	缓存已算 K/V 避免重算
FlashAttention	FlashAttention	IO 感知的分块注意力算法
推测解码	Speculative Decoding	小模型草拟 + 大模型验证
RLHF	RL from Human Feedback	人类反馈强化学习对齐
DPO	Direct Preference Optimization	无 RM 的偏好优化
CoT	Chain-of-Thought	思维链推理
PRM	Process Reward Model	过程奖励模型
RAG	Retrieval Augmented Generation	检索增强生成
SFT	Supervised Fine-Tuning	监督微调
LoRA	Low-Rank Adaptation	低秩适配微调
量化	Quantization	降低数值精度省资源
连续批处理	Continuous Batching	动态批处理提升吞吐
数据墙	Data Wall	高质量数据枯竭
能力收敛假说	Capability Convergence Hypothesis	能力由访问结构定价，而非规模
访问结构	Access Structure	压缩态 + 逐字索引双通道的完备类
AGI	Artificial General Intelligence	通用人工智能

(接下页)

(续上页)

术语	英文	一句话解释
具身智能	Embodied AI	AI 与物理世界交互
世界模型	World Model	AI 内部模拟环境
对齐	Alignment	让模型行为符合人类意图
红队	Red Teaming	对抗性安全测试
GRPO	Group Relative Policy Optimization	组相对策略优化（免 Critic）
SSM	State Space Model	状态空间模型（Mamba）
张量并行	Tensor Parallelism	单矩阵切多卡，NVLink 域内
流水线并行	Pipeline Parallelism	不同层放不同卡，跨节点
ZeRO	Zero Redundancy Optimizer	分片优化器状态省显存
算术强度	Arithmetic Intensity	FLOPs/Byte，判计算/访存受限
PagedAttention	Paged KV Cache	KV 分页管理，消碎片
MCP	Model Context Protocol	Agent 连接工具/数据的标准协议（2026 事实标准）
推测解码变体	EAGLE / Medusa	特征级 / 多头自草拟
MTP	Multi-Token Prediction	多 token 预测，兼作草拟器
YaRN	Yet another RoPE extension	RoPE 长上下文分段外推
QLoRA	Quantized LoRA	4-bit 基座 + LoRA 微调
NF4	NormalFloat 4-bit	正态感知 4-bit 量化格式
GPTQ / AWQ	—	离线最优 / 激活感知 INT4 量化
SmoothQuant	—	激活-权重量化难度迁移（W8A8）
RLAIF	RL from AI Feedback	AI 反馈替代人类反馈
越狱	Jailbreak	诱导模型违反安全约束的提示攻击
提示注入	Prompt Injection	经外部内容注入恶意指令
Test-time Compute	测试时计算	用推理时长换准确率
MCTS	Monte Carlo Tree Search	蒙特卡洛树搜索（推理路径）
CoT 忠实度	CoT Faithfulness	思考链是否反映真实决策依据
VAD	Voice Activity Detection	语音端点检测
EnCodec	—	神经声码编解码器（语音 token 化）
DiT	Diffusion Transformer	扩散 Transformer 生成骨干
3D VAE	—	视频时空潜空间压缩
GUI Agent	—	屏幕截图理解 + 操作规划执行

(接下页)

(续上页)

术语	英文	一句话解释
数据配比	Data Mixing	各来源数据比例设计
灾难性遗忘	Catastrophic Forgetting	新训练覆盖旧知识
困惑度	Perplexity	平均“候选词犹豫数”，exp 损失
MMLU / C-Eval	—	知识类通用基准（英/中）
GSM8K/MATH	—	数学推理基准
HumanEval/MBPP	—	代码能力基准

B 关键论文与延伸阅读

以下按主题列出本报告涉及的核心文献（均可经 arXiv 或官方博客获取），供延伸阅读与数据溯源：

架构基础

- Vaswani et al., 2017. *Attention Is All You Need* (arXiv:1706.03762) ——Transformer 原始论文；
- He et al., 2015. *Deep Residual Learning* (arXiv:1512.03385) ——残差连接，被 Transformer 直接继承；
- Su et al., 2021. *RoFormer: Rotary Position Embedding* (arXiv:2104.09864) ——RoPE；
- Peng et al., 2023. *YaRN* (arXiv:2309.00071) ——RoPE 长上下文扩展；
- Gu and Dao, 2023. *Mamba* (arXiv:2312.00752) ——选择性状态空间模型。

Scaling Law

- Kaplan et al., 2020. *Scaling Laws for Neural Language Models* (arXiv:2001.08361)；
- Hoffmann et al., 2022. *Training Compute-Optimal LLMs* (Chinchilla, arXiv:2203.15556)；
- Snell et al., 2024. *Scaling LLM Test-Time Compute Optimally* (arXiv:2408.03314) ——推理时扩展的开山之作；
- Chen et al., 2026. *Capability from Access Structure, Not Scale: Lower Bounds and Pre-Registered Tests for Hybrid Sequence Models* (CCH, arXiv:2607.14144) ——10.3 节的理论来源；
- Huh et al., 2024. *The Platonic Representation Hypothesis* (arXiv:2405.07987) ——CCH 所回应的表征收敛假说；
- Merrill and Sabharwal, 2023. *The Parallelism Tradeoff: Limitations of Log-Precision Transformers* (arXiv:2207.00729) ——“电路墙”的理论基础。

MoE 与注意力变体

- Fedus et al., 2021. *Switch Transformers* (arXiv:2101.03961)；
- Ainslie et al., 2023. *GQA* (arXiv:2305.13245)；
- Jiang et al., 2024. *Mixtral of Experts* (arXiv:2401.04088)；
- DeepSeek-AI, 2024. *DeepSeek-V2* (arXiv:2405.04434, MLA) 与 *DeepSeek-V3* (arXiv:2412.19437, 无辅助损失 MoE / MTP / FP8)。

训练与对齐

- Loshchilov and Hutter, 2019. *Decoupled Weight Decay Regularization* (AdamW, arXiv:1711.05101);
- Hu et al., 2021. *LoRA* (arXiv:2106.09685) ; Detrmers et al., 2023. *QLoRA* (arXiv:2305.14314);
- Ouyang et al., 2022. *InstructGPT* (arXiv:2203.02155) ——RLHF 三部曲;
- Bai et al., 2022. *Constitutional AI* (arXiv:2212.08073);
- Rafailov et al., 2023. *DPO* (arXiv:2305.18290);
- Shao et al., 2024. *DeepSeekMath* (GRPO, arXiv:2402.03300)。

推理系统与推理模型

- Dao et al., 2022. *FlashAttention* (arXiv:2205.14135);
- Kwon et al., 2023. *vLLM: PagedAttention* (arXiv:2309.06180);
- Leviathan et al., 2023. *Speculative Decoding* (arXiv:2211.17192); Li et al., 2024. *EAGLE* (arXiv:2401.15077);
- Wei et al., 2022. *Chain-of-Thought* (arXiv:2201.11903); Wang et al., 2022. *Self-Consistency* (arXiv:2203.11171);
- Lightman et al., 2023. *Let's Verify Step by Step* (PRM, arXiv:2305.20050);
- DeepSeek-AI, 2025. *DeepSeek-R1* (arXiv:2501.12948, Nature 封面论文);
- Qwen Team, 2025. *Qwen3 Technical Report* (arXiv:2505.09388)。

模型体系与多模态

- Brown et al., 2020. *GPT-3* (arXiv:2005.14165); OpenAI, 2023. *GPT-4 Technical Report* (arXiv:2303.08774);
- Touvron et al., 2023. *LLaMA 2* (arXiv:2307.09288); Grattafiori et al., 2024. *The Llama 3 Herd of Models* (arXiv:2407.21783);
- Radford et al., 2021. *CLIP* (arXiv:2103.00020); Radford et al., 2022. *Whisper* (arXiv:2212.04356);
- Liu et al., 2023. *LLaVA* (arXiv:2304.08485);
- Peebles and Xie, 2023. *Scalable Diffusion Models with Transformers (DiT)* (arXiv:2212.09748)。

行业动态溯源：各模型官方技术报告/系统卡（OpenAI、Anthropic、Google、Meta、DeepSeek、Qwen、Moonshot、智谱）；中文行业报道推荐机器之心、量子位与 36 氪 AI 频道；监管文本以网信办、欧盟委员会官网为准。

— 报告完 —

本报告基于公开技术报告、学术论文和行业动态整理。如需深入任何特定章节，可进一步展开。